

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN



NGUYỄN VĂN HOÀI

MSSV: 225571

**XÂY DỰNG HỆ THỐNG DỰ ĐOÁN VÀ
CẢNH BÁO SỚM NGUY CƠ ĐỘT QUỴ DỰA
TRÊN THUẬT TOÁN HỌC MÁY**


KHOÁ LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành Công nghệ thông tin

Mã số ngành: 7480201

Cần Thơ, tháng 06 năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN



NGUYỄN VĂN HOÀI

MSSV: 225571

**XÂY DỰNG HỆ THỐNG DỰ ĐOÁN VÀ
CẢNH BÁO SỚM NGUY CƠ ĐỘT QUỴ DỰA
TRÊN THUẬT TOÁN HỌC MÁY**

KHOÁ LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành Công nghệ thông tin

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

NCS. TRẦN VĂN THIỆN

Cần Thơ, Tháng 6 năm 2026

CHẤP THUẬN CỦA HỘI ĐỒNG

Luận văn tốt nghiệp, do sinh viên Nguyễn Văn Hoài thực hiện dưới sự hướng dẫn của Giảng viên Trần Văn Thiện. Luận văn tốt nghiệp đã báo cáo và được Hội đồng chấm Luận văn tốt nghiệp thông qua ngày ... tháng ... năm 2026.

Ủy viên

(Ký tên)

Thư ký

(Ký tên)

.....

GHI CHÚC DANH, HỌ TÊN

.....

GHI CHÚC DANH, HỌ TÊN

Phản biện 1

(Ký tên)

Phản biện 2

(Ký tên)

.....

GHI CHÚC DANH, HỌ TÊN

.....

GHI CHÚC DANH, HỌ TÊN

Giảng viên hướng dẫn

(Ký tên)

Chủ tịch hội đồng

(Ký tên)

.....

GHI CHÚC DANH, HỌ TÊN

.....

GHI CHÚC DANH, HỌ TÊN

LỜI CẢM ƠN

Trước hết, em xin gửi lời cảm ơn chân thành đến Ban Giám hiệu Trường Công nghệ số và Trí tuệ nhân tạo DNC – Đại học Nam Cần Thơ cùng quý thầy cô đã tận tình giảng dạy, truyền đạt cho em những kiến thức quý báu trong suốt quá trình học tập tại trường. Những kiến thức nền tảng đó là cơ sở quan trọng để em có thể thực hiện luận văn tốt nghiệp này.

Em xin chân thành cảm ơn Thầy Trần Văn Thiện – giảng viên hướng dẫn, đã quan tâm, hỗ trợ và tạo điều kiện cho em trong suốt quá trình thực hiện đề tài. Những ý kiến đóng góp và sự hướng dẫn tận tình của thầy giúp em nhận biết rõ các vấn đề, giải quyết và điều chỉnh để hoàn thiện khóa luận tốt nghiệp.

Em cũng xin cảm ơn quý thầy cô trong Khoa Công nghệ Thông tin đã truyền đạt cho em nhiều kiến thức chuyên môn và kinh nghiệm quý báu. Đây là nền tảng giúp em có thể kết hợp các nội dung về phát triển ứng dụng, xử lý ảnh, học sâu, cơ sở dữ liệu và kiến trúc hệ thống vào đề tài “Xây dựng hệ thống dự đoán và cảnh báo sớm nguy cơ đột quỵ dựa trên thuật toán Học máy”.

Trong quá trình thực hiện khóa luận, mặc dù em đã cố gắng hoàn thiện một cách tốt nhất, tuy nhiên do thời gian hạn chế và kiến thức thực tế còn hạn chế nên luận văn tốt nghiệp của em không tránh khỏi những thiếu sót. Em rất mong nhận được sự cảm thông và những ý kiến đóng góp quý báu từ quý thầy cô để em có thể hoàn thiện bản thân hơn trong thời gian tới.

Em xin chân thành cảm ơn.

Cần Thơ, ngày ... tháng ... năm 2026

Người thực hiện

(Ký và ghi rõ họ tên)

Nguyễn Văn Hoài

TRANG CAM KẾT

Em xin cam kết khóa luận tốt nghiệp với đề tài "Xây dựng hệ thống dự đoán và cảnh báo sớm nguy cơ đột quỵ dựa trên thuật toán Học máy" là công trình do chính em thực hiện dưới sự hướng dẫn của Thầy Trần Văn Thiện

Các nội dung trình bày trong khóa luận được xây dựng dựa trên quá trình tìm hiểu cơ sở lý thuyết, phân tích dữ liệu, xây dựng mô hình học máy, tích hợp công nghệ giải thích AI và đánh giá kết quả thực nghiệm. Những tài liệu, công trình nghiên cứu, bộ dữ liệu, thư viện và nguồn tham khảo được sử dụng đều được trích dẫn và ghi rõ trong phần tài liệu tham khảo theo đúng quy định.

Em xin cam kết các số liệu thực nghiệm, bảng biểu, hình ảnh minh họa và kết quả đánh giá được trình bày trong khóa luận phản ánh đúng kết quả nghiên cứu thực tế. Các kết quả này không được sao chép từ bất kỳ công trình nào khác. Mã nguồn của đề tài được công khai tại kho lưu trữ AI-Stroke-Prediction trên nền tảng GitHub.

Nếu có bất kỳ sai sót nào liên quan đến tính trung thực của nội dung, số liệu hoặc nguồn tham khảo trong khóa luận, em xin hoàn toàn chịu trách nhiệm trước Nhà trường, Khoa Công nghệ thông tin và Hội đồng chấm khóa luận tốt nghiệp.

Cần Thơ, ngày ... tháng ... năm 2026

Người thực hiện

(Ký và ghi rõ họ tên)

Nguyễn Văn Hoài

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, ngày ... tháng ... năm 2026

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)

.....

NHẬN XÉT CỦA GIẢNG VIÊN PHẢN BIỆN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, ngày ... tháng ... năm 2026

Giảng viên phản biện
(Ký và ghi rõ họ tên)

.....

TÓM TẮT

Đột quy (tai biến mạch máu não) là một trong những nguyên nhân hàng đầu gây tử vong và để lại di chứng tàn tật vĩnh viễn trên toàn thế giới. Việc dự báo sớm và sàng lọc nguy cơ đột quy đóng vai trò quan trọng trong công tác phòng ngừa. Tuy nhiên, các hệ thống dự báo sử dụng kỹ thuật học máy truyền thống thường vận hành theo mô hình "hộp đen" (black-box), gây khó khăn về tính minh bạch và dễ bị ảnh hưởng bởi vấn đề mất cân bằng dữ liệu y tế, đặc biệt khi phân phối lớp không đồng đều. Để giải quyết những tồn đọng này, nghiên cứu hướng đến việc thiết kế và xây dựng một Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS) dự báo nguy cơ đột quy đa tầng, tích hợp công nghệ Trí tuệ Nhân tạo có thể giải thích (Explainable AI - XAI).

Dựa trên bộ dữ liệu chuẩn hóa "Full-filled Brain Stroke Dataset" với tổng cộng 4.981 hồ sơ bệnh án điện tử và 11 trường dữ liệu quan trọng, nghiên cứu đã đối mặt với thách thức mất cân bằng lớp cực đoan (chỉ 4,98% ca dương tính). Kỹ thuật Borderline-SMOTE được áp dụng nhằm tái cân bằng dữ liệu, giảm thiểu hiện tượng "ảo giác độ chính xác" và cải thiện hiệu năng của mô hình. Thuật toán XGBoost được chọn làm cấu trúc phân loại trọng tâm, kết hợp với thư viện SHAP (SHapley Additive exPlanations) để chuyển hóa cơ chế suy luận toán học thành các giải thích dễ hiểu từ góc độ y khoa. Kiến trúc của mô hình sau đó được triển khai trên nền tảng ứng dụng Web tương tác thông qua framework Streamlit, tạo ra giao diện thân thiện cho người dùng.

Kết quả thực nghiệm cho thấy việc áp dụng Borderline-SMOTE giúp tăng đáng kể độ nhạy (Recall) từ 38,56% lên đến 82,15%, giảm tối đa nguy cơ bỏ sót các trường hợp có bệnh trong thực tế. Thuật toán XGBoost biểu hiện hiệu năng cao với diện tích dưới đường cong AUC-ROC đạt 0,8612 và F1-Score đạt 0,7834. Về tính minh bạch, phân tích toàn cục của SHAP chỉ ra các yếu tố như tuổi tác (age), mức đường huyết trung bình (avg_glucose_level) và chỉ số khối cơ thể (BMI) là những nhân tố trọng yếu góp phần làm tăng nguy cơ đột quy, hoàn toàn phù hợp với các nghiên cứu y văn hiện hành. Ngoài ra, hệ thống vận hành ổn định, cho phép phân tầng nguy cơ nhanh chóng và xuất báo cáo cá nhân hóa dưới dạng biểu đồ thác nước

trực quan, hỗ trợ tốt trong quá trình đưa ra quyết định.

Thành quả của nghiên cứu không chỉ dừng lại ở việc chuẩn hóa quy trình phân tích dữ liệu y sinh học ứng dụng học máy mà còn tạo ra một công cụ phần mềm khả thi trong thực tế. Hệ thống mang lại tiềm năng ứng dụng đáng kể tại các cơ sở y tế cấp cơ sở, hỗ trợ đội ngũ y bác sĩ đưa ra quyết định chẩn đoán nhanh chóng, chính xác và dựa trên luận cứ khoa học rõ ràng.

Từ khóa: Đột quy, Trí tuệ nhân tạo có thể giải thích (XAI), SHAP, Borderline-SMOTE, XGBoost, Hệ thống hỗ trợ quyết định lâm sàng (CDSS).

MỤC LỤC

CHƯƠNG 1 GIỚI THIỆU	1
1.1. Đặt vấn đề	1
1.2. Lý do chọn đề tài	3
1.3. Mục tiêu của luận văn	4
1.4. Đối tượng và phạm vi thực hiện	5
1.5. Phương pháp thực hiện	6
1.6. Ý nghĩa thực tiễn của hệ thống	7
1.7. Bố cục luận văn	8
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	11
2.1. Tổng quan về đột quỵ não và nhu cầu dự báo sớm	11
2.2. Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS)	12
2.3. So sánh các mô hình	13
2.4. Bộ dữ liệu “Brain stroke prediction dataset” và tiền xử lý dữ liệu y tế	14
2.5. Kỹ thuật xử lý mất cân bằng dữ liệu bằng SMOTE	16
2.6. Cơ chế giải thích Trí tuệ Nhân tạo minh bạch với framework SHAP	18
2.7. Các độ đo đánh giá mô hình phân loại y tế	21
CHƯƠNG 3 PHÂN TÍCH THIẾT KẾ VÀ TRIỂN KHAI HỆ THỐNG	23
3.1. Mô tả tổng quan hệ thống	23
3.2. Phân tích tác nhân và yêu cầu hệ thống	25
3.2.1. Các tác nhân tương tác với hệ thống (Actors)	25
3.2.2. Các yêu cầu chức năng trọng tâm (Functional Requirements)	26
3.3. Quy trình tiền xử lý và tăng cường dữ liệu	26
3.4. Huấn luyện và tinh chỉnh siêu tham số mô hình XGBoost	28
3.5. Tích hợp SHAP XAI vào pipeline dự báo	30
3.6. Thiết kế kiến trúc hệ thống web	31
3.7. Thiết kế giao diện người dùng	31
3.8. Triển khai hệ thống	32
CHƯƠNG 4 THỰC NGHIỆM VÀ ĐÁNH GIÁ HỆ THỐNG	34
4.1. Môi trường thực nghiệm	34
4.2. Dữ liệu và kịch bản kiểm thử	34
4.3. Đánh giá hiệu năng các mô hình	35
4.4. So sánh các chiến lược xử lý mất cân bằng dữ liệu	38
4.5. Đánh giá hệ thống giải thích SHAP	39
4.6. Kiểm thử chức năng hệ thống web	40
4.7. Nhận xét tổng hợp	41
CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	44

5.1 Kết quả đạt được	44
5.2 Hạn chế	45
5.3 Hướng phát triển	46
TÀI LIỆU THAM KHẢO	48

DANH SÁCH BẢNG

Bảng 2.1 Bảng từ điển dữ liệu (Data Dictionary) của tập dữ liệu dự báo đột quy	15
Bảng 2.2 Ma trận nhầm lẫn (Confusion Matrix)	22
Bảng 3.1 Thành phần công nghệ và vai trò chức năng trong kiến trúc CDSS	24
Bảng 4.1 Môi trường hệ thống chuẩn đoán nguy cơ đột quy	34
Bảng 4.2 Cấu trúc các tập dữ liệu trước và sau khi xử lý mất cân bằng	35
Bảng 4.3 Đối chiếu hiệu năng giữa các thuật toán học máy trên tập kiểm thử	35
Bảng 4.4 Đánh giá hiệu năng các chiến lược xử lý mất cân bằng phân phối lớp trên cấu trúc XGBoost	38
Bảng 4.5 Xếp hạng tầm quan trọng toàn cục của các đặc trưng theo giá trị SHAP	39
Bảng 4.6 Các kịch bản và kết quả kiểm thử chức năng hệ thống	41

DANH SÁCH HÌNH

Hình 1.1 Biểu đồ thống kê đột quỵ Việt Nam	2
Hình 2.1 Minh họa không gian đặc trưng và cơ chế nội suy mẫu nhân tạo của thuật toán SMOTE.	18
Hình 3.1 Quy trình phát hiện khuôn mặt, căn chỉnh và trích xuất embedding trong hệ thống AuEdu.	25
Bảng 3.2 Các siêu tham số tốt nhất cho mô hình XGBoost	29
Bảng 3.3 Quy trình thiết lập và triển khai hệ thống dự báo	33
Hình 4.1 Biểu đồ đường cong ROC (ROC Curve) đánh giá khả năng phân lớp và diện tích AUC của các thuật toán.	36
Hình 4.2 Biểu đồ trực quan hóa so sánh các độ đo hiệu năng y tế (F1-Score, Recall, Precision, Accuracy) giữa các mô hình.	37

DANH MỤC TỪ VIẾT TẮT

Ký hiệu viết tắt	Cụm từ tiếng Anh đầy đủ	Ý nghĩa tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
AUC-ROC	Area Under the Receiver Operating Characteristic Curve	Diện tích dưới đường cong đặc trưng hoạt động của hệ thống
CatBoost	Categorical Boosting	Thuật toán tăng cường cho biến phân loại
CDSS	Clinical Decision Support System	Hệ thống hỗ trợ quyết định lâm sàng
EHR	Electronic Health Record	Hồ sơ sức khỏe điện tử
LightGBM	Light Gradient Boosting Machine	Thuật toán máy tăng cường Gradient hạng nhẹ
ML	Machine Learning	Học máy
SHAP	SHapley Additive exPlanations	Phương pháp giải thích cộng tính Shapley
SMOTE	Synthetic Minority Over-sampling Technique	Kỹ thuật sinh mẫu thiểu số nhân tạo
XAI	Explainable Artificial Intelligence	Trí tuệ nhân tạo có thể giải thích
XGBoost	Extreme Gradient Boosting	Thuật toán tăng cường Gradient cực độ


CHƯƠNG 1

GIỚI THIỆU

1.1. Đặt vấn đề

Đột quỵ não (Stroke) được y văn hiện đại định nghĩa là một hội chứng lâm sàng cấp tính, đặc trưng bởi sự khởi phát đột ngột và tiến triển nhanh chóng của các khiếm khuyết chức năng thần kinh khu trú hoặc toàn thể. Các triệu chứng này kéo dài quá 24 giờ hoặc dẫn đến tử vong trong thời gian ngắn mà không tìm thấy nguyên nhân nào khác ngoài thương tổn mạch máu não [1]. Theo báo cáo cập nhật từ Tổ chức Đột quỵ Thế giới (WSO) và công bố mới nhất từ Khảo sát Gánh nặng Bệnh tật Toàn cầu (GBD), căn bệnh này tiếp tục giữ vững vị trí là nguyên nhân gây tử vong đứng thứ hai và là tác nhân hàng đầu dẫn đến tình trạng tàn phế dài hạn trên phạm vi toàn cầu [2]. Các số liệu thống kê chỉ ra một sức ép khổng lồ khi thế giới ghi nhận hơn 12 triệu ca khởi phát mới mỗi năm; trong đó, hơn 6,5 triệu bệnh nhân không thể qua khỏi và hàng triệu người sống sót phải gánh chịu các di chứng thần kinh vĩnh viễn, tước bỏ hoàn toàn khả năng tự chủ trong sinh hoạt và lao động [1], [2].

Tại Việt Nam, bức tranh dịch tễ học của đột quỵ đang diễn biến theo chiều hướng hết sức phức tạp và đặt ra những thách thức mang tính chiến lược cho hệ thống y tế công cộng. Các nghiên cứu đánh giá quy mô quốc gia gần đây cho thấy mạng lưới y tế nội địa tiếp nhận khoảng 200.000 ca đột quỵ mỗi năm. Đáng quan ngại là tỷ lệ tử vong vẫn neo ở ngưỡng rất cao (khoảng 20-25%) và có tới gần 90% người bệnh sau khi vượt qua giai đoạn cấp cứu phải đối mặt với các tổn thương chức năng từ trung bình đến nghiêm trọng [3]. Một thực trạng mang tính báo động đỏ là sự dịch chuyển nhân khẩu học của căn bệnh này: đột quỵ đang có xu hướng "trẻ hóa" với tốc độ gia tăng đáng kinh ngạc ở nhóm người bệnh dưới 45 tuổi [4]. Biến cố đột quỵ xảy ra ở độ tuổi lao động vàng không chỉ là thảm kịch đối với sinh mệnh cá nhân mà còn tạo ra các cú sốc tài chính nặng nề, làm kiệt quệ nguồn lực an sinh xã hội do chi phí điều trị cấp tính và quá trình phục hồi chức năng kéo dài [3], [4].



Hình 1.1 Biểu đồ thống kê đột quỵ Việt Nam

Mặc dù để lại những hệ lụy lâm sàng tàn khốc, các nghiên cứu đa trung tâm đều khẳng định đột quỵ hoàn toàn có thể được ngăn chặn nếu mạng lưới y tế dự phòng phát hiện sớm và can thiệp kịp thời vào các yếu tố nguy cơ. Các tác nhân rủi ro cốt lõi đã được y học chỉ điểm rõ ràng, bao gồm: tăng huyết áp, đái tháo đường, rối loạn chuyển hóa lipid máu, lạm dụng thuốc lá, béo phì, lối sống tĩnh tại, bệnh lý tim mạch nền và sự lão hóa tự nhiên [5]. Tuy nhiên, trên thực tế lâm sàng, các yếu tố này không vận hành độc lập mà tương tác phi tuyến tính và đan xen chặt chẽ với nhau, tạo ra một ma trận bệnh lý vô cùng phức tạp [5]. Việc đánh giá chính xác rủi ro này đòi hỏi các bác sĩ phải có trình độ chuyên môn nội thần kinh sâu rộng và tốn rất nhiều thời gian phân tích. Lỗ hổng này càng lộ rõ tại hệ thống y tế cơ sở tuyến huyện hoặc vùng sâu vùng xa, nơi đang đối mặt với tình trạng thiếu hụt trầm trọng đội ngũ chuyên gia thần kinh học, dẫn đến hệ lụy tất yếu là sự chậm trễ, bỏ sót hoặc đánh giá sai lệch cửa sổ vàng dự báo của người dân.

Để tháo gỡ bài toán quá tải và điểm nghẽn về năng lực sàng lọc tại y tế cơ sở, sự bùng nổ của kỷ nguyên dữ liệu y tế số (Electronic Health Records) kết hợp cùng những bước tiến nhảy vọt trong lĩnh vực Trí tuệ Nhân tạo (AI) và Học máy (Machine Learning) đã mở ra một hướng đi mang tính đột phá [6]. Không giống

như tư duy chẩn đoán truyền thống của con người thường bị giới hạn bởi khả năng xử lý số lượng biến số, các thuật toán Học máy nâng cao sở hữu năng lực tính toán không gian dữ liệu đa chiều khổng lồ. Chúng có khả năng tự động bóc tách, khai phá các mẫu hình (patterns) ẩn giấu và những mối tương quan chéo phức tạp giữa các chỉ số lâm sàng để đưa ra dự báo nguy cơ với độ chuẩn xác vượt trội [6]. Sự hội tụ giữa sức mạnh tính toán của máy tính và tri thức y học chính là nền tảng cốt lõi cho sự ra đời của các Hệ thống Hỗ trợ Quyết định Lâm sàng (Clinical Decision Support System - CDSS) thế hệ mới. Ứng dụng này hứa hẹn sẽ trở thành một "bác sĩ ảo" đặc lực, đóng vai trò như một công cụ tầm soát thông minh nhằm bù đắp sự thiếu hụt nhân lực và chuẩn hóa phác đồ phòng ngừa cá nhân hóa tại mọi cấp độ y tế [7].

1.2. Lý do chọn đề tài

Ý tưởng thực hiện đề tài bắt nguồn từ sự giao thoa giữa một thực trạng lâm sàng nhức nhối và những điểm nghẽn kỹ thuật trong việc ứng dụng công nghệ hiện đại vào y tế. Trong những năm gần đây, mô hình bệnh tật liên quan đến tai biến mạch máu não đang ghi nhận xu hướng dịch chuyển nhân khẩu học đáng lo ngại; đột quỵ không còn là biến cố sức khỏe đặc thù của nhóm người cao tuổi [4]. Hệ lụy từ lối sống tĩnh tại, áp lực tâm lý kéo dài và chế độ dinh dưỡng thiếu khoa học đang đẩy nhanh tiến trình trẻ hóa đột quỵ, biến nó thành mối đe dọa thường trực đối với lực lượng lao động nòng cốt của xã hội [4], [8]. Tại Việt Nam, tình hình đột quỵ gia tăng không chỉ là thách thức y tế đơn thuần mà đã trở thành một bài toán công nghệ phân tích dữ liệu cần được giải quyết bằng các phương pháp hiện đại. Đáng chú ý, cộng đồng y khoa hiện nay vẫn giữ một thái độ thận trọng, chần chừ trong việc tích hợp Trí tuệ Nhân tạo (AI) vào chẩn đoán lâm sàng chủ yếu do e ngại về tính toàn vẹn, độ tin cậy và sai số hệ thống của thuật toán [8]. Đề tài được hình thành với khát vọng phá vỡ rào cản đó, hướng tới việc xây dựng một hệ thống chẩn đoán và dự báo có độ chuẩn xác cao, thiết lập niềm tin khoa học vững chắc cho các chuyên gia y tế.

Lý do thứ hai xuất phát từ tính cấp bách và những tác động kinh tế - xã hội sâu sắc mà đột quỵ gây ra. Mỗi một ca khởi phát đột quỵ không chỉ là một bi kịch đối với sinh mệnh cá nhân người bệnh, mà còn kéo theo những tổn thất khổng lồ về tài chính cho gia đình và đặt hệ thống an sinh xã hội vào trạng thái quá tải do chi phí điều trị nội trú tích cực và phục hồi chức năng thần kinh dài hạn vô cùng đắt đỏ [9]. Việc nghiên cứu và thiết lập một giải pháp công nghệ có khả năng sàng lọc, phân tầng phổ nguy cơ từ sớm sẽ đóng vai trò như một công cụ dự phòng chủ động,

giúp các cơ sở y tế đưa ra can thiệp kịp thời trước khi tổn thương thực thể xảy ra, từ đó giảm thiểu tối đa áp lực nhân lực và vật lực cho toàn bộ hệ thống y tế [9].

Lý do thứ ba, nhìn từ góc độ khoa học dữ liệu, đề tài tập trung giải quyết triệt để hai "lỗ hổng" kỹ thuật lớn nhất đang cản trở bước tiến của AI trong y học: sự mất cân bằng phân phối dữ liệu tự nhiên (Class Imbalance) và bản chất "hộp đen" (Black-box) của các mô hình học máy [10], [11]. Trong các tập dữ liệu y sinh thực tế, tỷ lệ mẫu dương tính (bệnh nhân đột quỵ) luôn chiếm một phần rất nhỏ so với quần thể người khỏe mạnh, khiến các mô hình học máy thông thường dễ rơi vào cái bẫy thiên lệch (bias), thiên vị lớp đa số và bỏ sót các ca bệnh nguy cấp [10]. Đồng thời, sự thiếu minh bạch trong cơ chế suy luận của các thuật toán phức tạp khiến bác sĩ không thể lý giải được nguyên nhân cốt lõi đằng sau một dự báo [11]. Đề tài này hướng đến việc xử lý dứt điểm hai rào cản trên bằng cách phối hợp chiến lược lấy mẫu thông minh và công nghệ tường minh hóa thuật toán.

Lý do thứ tư nằm ở nền tảng dữ liệu thực nghiệm phục vụ nghiên cứu. Để đảm bảo tính khách quan, khoa học và thực chất, đề tài quyết định lựa chọn khai thác bộ dữ liệu Brain stroke prediction dataset trên nền tảng Kaggle. Đây là tập dữ liệu y tế chuẩn mực đã trải qua quá trình lọc nhiễu nghiêm ngặt, khắc phục triệt để các sai số hệ thống và được nội suy toàn vẹn các giá trị khuyết thiếu (full-filled data) [12]. Việc huấn luyện mô hình trên một nền tảng dữ liệu sạch và có cấu trúc rõ ràng không chỉ nâng cao độ tin cậy của các chỉ số đánh giá hiệu năng (như AUC-ROC, F1-Score) mà còn đáp ứng nghiêm ngặt tiêu chuẩn về khả năng kiểm chứng, kiểm định chéo và tái lập (Reproducibility) của toàn bộ công trình nghiên cứu [12].

Cuối cùng, việc thiết kế một Hệ thống Hỗ trợ Quyết định Lâm sàng có khả năng giải thích (Explainable CDSS) là bước đi bắt buộc xu hướng dịch chuyển toàn cầu trong lĩnh vực Nghiên cứu Triển khai AI Y tế (Implementation Research). Theo các quy chuẩn mới nhất về công nghệ y tế số, tính minh bạch và năng lực lý giải cục bộ (Interpretability) không còn được coi là một tính năng phụ trợ, mà đã trở thành điều kiện tiên quyết mang tính bản lề để bất kỳ hệ thống thông minh nào có thể vượt qua vòng thẩm định, tích hợp an toàn và được chấp nhận rộng rãi trong thực hành lâm sàng thực tế tại các bệnh viện [13].

1.3. Mục tiêu của luận văn

Đích đến cao nhất của nghiên cứu này là phát triển hoàn thiện một công cụ Hỗ trợ Quyết định Lâm sàng (CDSS) có năng lực phân loại xác suất mắc đột quỵ. Hệ thống này sẽ khai thác sức mạnh của nhóm thuật toán học máy kết hợp với các kỹ thuật minh bạch hóa AI, từ đó giúp các chuyên gia y tế thiết lập phác đồ dự

phòng chính xác hơn. Để đạt được kết quả trên, đề án cần hoàn thành các bước cụ thể:

- (1) Khai thác, làm sạch và khảo sát thống kê bộ dữ liệu Brain stroke prediction dataset.
- (2) Áp dụng kỹ thuật Borderline-SMOTE để điều chỉnh tỷ lệ chênh lệch giữa các nhóm nhãn.
- (3) Xây dựng, tìm kiếm tham số tối ưu và kiểm định chất lượng ba kỹ thuật phân lớp.
- (4) Bổ sung tính năng SHAP để diễn giải nguyên nhân bệnh lý theo hai phương diện: diện rộng và cá nhân hóa.
- (5) Cuối cùng, lập trình một nền tảng Web trực quan hiển thị kết quả dự đoán.

1.4. Đối tượng và phạm vi thực hiện

Đối tượng nghiên cứu: Khóa luận tập trung nghiên cứu chuyên sâu vào cấu trúc toán học của các mô hình Học máy và Trí tuệ Nhân tạo có thể giải thích (Explainable AI - XAI), ứng dụng trực tiếp vào bài toán phân lớp và dự báo sớm nguy cơ đột quỵ não [14].

Đối tượng sử dụng: Hệ thống được thiết kế hướng tới tệp người dùng cuối (end-users) là đội ngũ bác sĩ đa khoa, bác sĩ nội khoa và các chuyên viên y tế tuyến cơ sở. Ứng dụng đóng vai trò như một công cụ tham chiếu kỹ thuật số (digital reference tool) thông minh, hỗ trợ quá trình chẩn đoán thứ cấp, giúp nhân viên y tế củng cố các quyết định sàng lọc lâm sàng và tối ưu hóa thời gian tư vấn bệnh nhân [15].

Phạm vi dữ liệu: Không gian tri thức của hệ thống được huấn luyện và kiểm định giới hạn trên bộ dữ liệu y sinh chuẩn hóa "Full-filled Brain Stroke Dataset" trích xuất từ nền tảng lưu trữ khoa học dữ liệu Kaggle. Quần thể dữ liệu bao gồm 4.981 hồ sơ bệnh án điện tử độc lập, được khoanh vùng trong 11 trường đặc trưng cốt lõi phản ánh toàn diện các khía cạnh: thông tin nhân khẩu học, chỉ số sinh lý lâm sàng và thói quen sinh hoạt. Điểm ưu việt của giới hạn dữ liệu này là toàn bộ không gian mẫu đã được tiền xử lý toàn vẹn (full-filled), khắc phục triệt để độ nhiễu và sự khuyết thiếu thông tin, từ đó cung cấp một nền tảng vững chắc để triệt tiêu các sai lệch thuật toán ngay từ khâu đầu vào [16].

Phạm vi kỹ thuật lõi: Về mặt thuật toán, nghiên cứu khoanh vùng triển khai dựa trên kiến trúc Tăng cường Gradient cấu trúc cây (đại diện tiêu biểu là thuật toán XGBoost) do tính ưu việt đã được chứng minh của nó trong việc xử lý dữ liệu y tế dạng bảng [17]. Khóa luận cũng giới hạn việc áp dụng kỹ thuật SMOTE (cụ thể là Borderline-SMOTE) cho bài toán xử lý mất cân bằng phân phối lớp tự nhiên, và sử dụng độc quyền cơ chế SHAP (SHapley Additive exPlanations) thuộc lý thuyết trò chơi để bóc tách, định lượng tính minh bạch của mô hình.

Phạm vi triển khai phần mềm: Sản phẩm đầu ra của nghiên cứu không bao gồm việc tích hợp phần cứng y tế (IoT devices) mà được giới hạn dưới hình thức một Ứng dụng Web tương tác đa nền tảng (Interactive Web Application). Toàn bộ kiến trúc phần mềm được đóng gói bằng công nghệ container hóa và công khai mã nguồn mở minh bạch tại kho lưu trữ số AI-Stroke-Prediction trên nền tảng GitHub, phục vụ mục đích đánh giá học thuật và làm tiền đề cho các nghiên cứu y khoa số kế tiếp.

1.5. Phương pháp thực hiện

Đề tài áp dụng phương pháp luận nghiên cứu thực nghiệm vòng lặp (Iterative Empirical Research) kết hợp chặt chẽ giữa tổng quan tài liệu hệ thống, thực nghiệm mô hình toán học và kỹ nghệ phần mềm ứng dụng [18]. Để hiện thực hóa các mục tiêu đã đề ra, quy trình triển khai nghiên cứu được chuẩn hóa và thực hiện thông qua năm giai đoạn tiến trình sau đây:

Giai đoạn 1: Tổng quan lý thuyết và khảo sát các công trình liên quan: Tiến hành tra cứu, phân tích và tổng hợp hệ thống các tài liệu bản lẻ, báo cáo dịch tễ học và bài báo khoa học uy tín quốc tế liên quan đến cơ chế bệnh sinh của đột quỵ não. Khảo sát sâu các kiến trúc thiết kế của Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS) hiện hành, cùng các bước tiến mới trong việc tối ưu hóa thuật toán Học máy và framework Trí tuệ Nhân tạo có thể giải thích (XAI) nhằm thiết lập nền tảng lý thuyết vững chắc cho đề tài [18], [19].

Giai đoạn 2: Trích xuất, xử lý kỹ nghệ dữ liệu và thiết lập Data Pipeline: Tập trung khai thác và phân tích khám phá dữ liệu (EDA) trên bộ dữ liệu Brain stroke prediction dataset. Thực hiện các kỹ thuật dọn dẹp dữ liệu chuyên sâu bao gồm: chuẩn hóa cấu trúc trường dữ liệu, cô lập ngoại lai (outliers), và mã hóa biến phân loại (Encoding). Đồng thời, thiết lập cơ chế chia tách tập dữ liệu theo tỷ lệ phân

tầng (Stratified Split) để bảo toàn phân phối lớp nhãn tự nhiên giữa tập huấn luyện và tập kiểm tra, triệt tiêu hoàn toàn nguy cơ rò rỉ thông tin (Data Leakage) [19].

Giai đoạn 3: Thực nghiệm chiến lược cân bằng mẫu và huấn luyện mô hình Ensemble: Triển khai thuật toán lấy mẫu nâng cao Borderline-SMOTE trên tập dữ liệu huấn luyện để giải quyết hiện tượng mất cân bằng phân phối lớp (Class Imbalance). Tập trung nghiên cứu sự đánh đổi hiệu năng thông qua việc tinh chỉnh tỷ lệ lấy mẫu để đạt điểm cân bằng tối ưu giữa độ nhạy (Recall) và độ chính xác (Precision) [20]. Trên nền tảng dữ liệu đã xử lý, tiến hành huấn luyện song song ba mô hình thuật toán mạnh mẽ bao gồm XGBoost, LightGBM và CatBoost; đồng thời áp dụng cơ chế "Ràng buộc Đơn điệu" (Monotone Constraints) để đảm bảo suy luận của AI tuân thủ đúng logic sinh lý bệnh học lâm sàng [20].

Giai đoạn 4: Tích hợp engine giải thích XAI và đánh giá hiệu năng toàn diện: Nhúng thư viện SHAP (SHapley Additive exPlanations) thuộc lý thuyết trò chơi hợp tác vào pipeline suy luận sau huấn luyện. Tiến hành đo lường, bóc tách và trực quan hóa tầm quan trọng của các biến số ở cấp độ toàn cục (Global SHAP) lẫn cấp độ cá nhân hóa cho từng hồ sơ bệnh nhân (Local SHAP) [21]. Hiệu năng của các mô hình được đánh giá chéo khách quan trên tập kiểm tra độc lập thông qua các độ đo y khoa cốt lõi như F1-Score, Recall, Precision và diện tích dưới đường cong ROC (AUC-ROC) [21].

Giai đoạn 5: Phát triển kiến trúc ứng dụng Web, đóng gói và triển khai đám mây: Chuyển giao các artifact mô hình và explainer đã tối ưu sang môi trường ứng dụng thực tế. Thiết kế giao diện người dùng tương tác bằng framework Streamlit, phục vụ thao tác sàng lọc nhanh của bác sĩ [22]. Toàn bộ mã nguồn, thư viện phụ thuộc và môi trường vận hành được đóng gói cô lập bằng công nghệ container hóa Docker. Cuối cùng, thực hiện kiểm thử hộp đen (Black-box testing) trước khi triển khai chính thức ứng dụng lên hạ tầng điện toán đám mây Hugging Face Spaces [22].

1.6. Ý nghĩa thực tiễn của hệ thống

Về mặt y tế lâm sàng, hệ thống cung cấp cho các nhà lâm sàng một công cụ tham chiếu kỹ thuật số tốc độ cao, hỗ trợ chuẩn hóa quy trình đánh giá rủi ro đột quỵ

thông qua việc phân tích tự động ma trận đa biến từ các chỉ số sinh lý và hành vi sức khỏe của bệnh nhân [23]. Sự khác biệt lớn nhất mang lại giá trị thực tiễn là cơ chế phân tầng rủi ro đa cấp độ (thấp, trung bình, cao) kết hợp cùng hệ thống giải thích cục bộ SHAP. Cơ chế này giúp "giải mã" bức tranh rủi ro của từng cá nhân, cho phép bác sĩ nhận diện chính xác mũi nhọn nguy cơ đang đóng vai trò định hướng (ví dụ: huyết áp, lượng đường trong máu, hay chỉ số BMI). Từ các dữ kiện minh bạch này, các chuyên gia y tế có thể đưa ra các phác đồ can thiệp chủ động, trúng đích và cá nhân hóa, qua đó tối ưu hóa hiệu quả điều trị và tận dụng tối đa "cửa sổ vàng" trong y tế dự phòng [23].

Về mặt công nghệ và kỹ nghệ phần mềm, khóa luận đóng góp một mô hình tham chiếu (reference architecture) điển hình cho việc tích hợp thành công Trí tuệ Nhân tạo có thể giải thích (XAI) vào không gian của các Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS). Nghiên cứu đã cung cấp các giải pháp thực nghiệm sắc bén nhằm giải quyết song song hai bài toán kinh điển của AI y tế: sự mất cân bằng phân phối lớp tự nhiên (Class Imbalance) và rào cản "hộp đen" (Black-box) cản trở niềm tin của người dùng [24]. Đặc biệt, việc công khai mã nguồn mở của dự án (tại kho lưu trữ AI-Stroke-Prediction) góp phần thúc đẩy mạnh mẽ văn hóa khoa học mở (Open Science). Thành quả này tạo lập một bộ khung (framework) toàn vẹn, tạo điều kiện thuận lợi để cộng đồng kỹ sư và các nhà nghiên cứu y sinh có thể dễ dàng kiểm định, tái sử dụng, hoặc mở rộng quy mô hệ thống trên các tập dữ liệu đa trung tâm trong tương lai [24].

Về mặt giáo dục và định hướng đào tạo, trong bối cảnh chuyển đổi số đang diễn ra mạnh mẽ, đồ án là một minh chứng sinh động cho năng lực chuyển hóa các lý thuyết phức tạp của ngành Công nghệ Thông tin vào việc giải quyết những bài toán cấp bách mang tính sinh tử trong lĩnh vực Y tế số (Digital Health) [25]. Thành quả nghiên cứu này không chỉ phản ánh chất lượng đầu ra của sinh viên mà còn khẳng định sự tương thích tuyệt đối với định hướng đào tạo kỹ sư liên ngành ứng dụng cao, gắn chặt tri thức hàn lâm với sứ mệnh giải quyết các vấn đề thực tiễn của Trường Đại học Nam Cần Thơ (DNC).

1.7 Bố cục luận văn

Nội dung nghiên cứu và toàn bộ tiến trình hiện thực hóa hệ thống trong khóa luận được cấu trúc logic và tổ chức chặt chẽ thành 5 chương chính với các nhiệm vụ chuyên biệt sau đây:

Chương 1: Giới thiệu. Trình bày tổng quan bối cảnh nghiên cứu thông qua phân đặt vấn đề về thực trạng dịch tễ học đột quỵ và xu hướng trẻ hóa bệnh lý.

Chương này cũng tập trung làm rõ tính cấp thiết thông qua lý do chọn đề tài, xác định rõ ràng mục tiêu tổng quát và các mục tiêu cụ thể, khoanh vùng đối tượng và phạm vi giới hạn của nghiên cứu, thiết lập phương pháp luận thực nghiệm và đúc kết những giá trị ý nghĩa thực tiễn mà hệ thống mang lại.

Chương 2: Cơ sở lý thuyết. Xây dựng nền tảng lý thuyết bản lề cho toàn bộ đề tài. Nội dung chương đi sâu phân tích cơ chế sinh lý bệnh học của đột quỵ não và kiến trúc tổng quan của Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS). Đồng thời, chương này cũng hệ thống hóa cơ sở toán học của các thuật toán Học máy kết hợp nâng cao bao gồm XGBoost, LightGBM và CatBoost; mô tả cấu trúc không gian đặc trưng của bộ dữ liệu Brain stroke prediction dataset; phân tích kỹ thuật lấy mẫu Borderline-SMOTE trong xử lý mất cân bằng và framework giải thích Trí tuệ Nhân tạo minh bạch SHAP XAI cùng các độ đo hiệu năng y tế.

Chương 3: Phân tích thiết kế và Triển khai hệ thống. Mô tả chi tiết kiến trúc phân lớp của hệ thống và quy trình kỹ nghệ phần mềm đầu cuối (End-to-End). Chương này tập trung bóc tách các bước chuyển giao công nghệ bao gồm: xây dựng offline pipeline để tiền xử lý và làm sạch dữ liệu; thiết kế, huấn luyện và tinh chỉnh siêu tham số cho các mô hình áp đặt ràng buộc đơn điệu (Monotone Constraints); tích hợp TreeExplainer của SHAP vào pipeline suy luận; và cuối cùng là thiết kế kiến trúc backend, phát triển giao diện Web tương tác bằng Streamlit.

Chương 4: Thực nghiệm và Đánh giá hệ thống. Báo cáo và phân tích sâu các kết quả định lượng thu được từ môi trường thực nghiệm. Chương này trình bày các kịch bản kiểm thử độc lập trên tập dữ liệu kiểm tra; thực hiện đối chiếu và đánh giá chéo hiệu năng phân loại của ba mô hình (XGBoost, LightGBM, CatBoost) qua các chỉ số AUC-ROC, Recall, F1-Score; phân tích tác động y khoa của chiến lược tối ưu hóa Borderline-SMOTE; kiểm định tính nhất quán của hệ thống giải thích nguyên nhân SHAP cá nhân hóa và báo cáo kết quả kiểm thử chức năng hộp đen của ứng dụng Web.

Chương 5: Kết luận và Hướng phát triển. Tổng kết toàn bộ các thành quả định tính và định lượng mà nghiên cứu đã đạt được trong việc xây dựng hệ thống CDSS dự báo đột quỵ đa tầng. Trên cơ sở đó, chương này thẳng thắn nhìn nhận,

phân tích các mặt hạn chế còn tồn tại của mô hình dữ liệu và hạ tầng phần mềm hiện tại, từ đó đề xuất các giải pháp tối ưu hóa, định hướng nghiên cứu nội địa hóa dữ liệu và lộ trình phát triển mở rộng hệ thống trong tương lai.

CHƯƠNG 2

CƠ SỞ LÝ THUYẾT

2.1. Tổng quan về đột quỵ não và nhu cầu dự báo sớm

Đột quỵ não (Stroke) là một biến cố y khoa khẩn cấp, khởi phát khi dòng tuần hoàn máu cung cấp cho não bộ bị suy giảm đột ngột hoặc gián đoạn hoàn toàn, dẫn đến tình trạng thiếu hụt oxy, dinh dưỡng và gây hoại tử tế bào thần kinh khu trú [26]. Dựa trên cơ chế sinh lý bệnh học, đột quỵ được phân loại thành hai thể lâm sàng cơ bản: đột quỵ thiếu máu cục bộ (Ischemic Stroke) và đột quỵ xuất huyết (Hemorrhagic Stroke). Trong đó, thể thiếu máu cục bộ chiếm tỷ lệ áp đảo với xấp xỉ 87% tổng số ca mắc, nguyên nhân chủ yếu xuất phát từ sự tắc nghẽn của các huyết khối tĩnh mạch hoặc mảng xơ vữa động mạch làm hẹp lòng mạch [27]. Ở chiều ngược lại, đột quỵ xuất huyết khởi phát từ sự vỡ nứt của các mao mạch não bị suy yếu, khiến máu tràn trực tiếp vào nhu mô nội sọ hoặc khoang dưới nhện. Hiện tượng này không chỉ gây tổn thương do thiếu máu mà còn tạo ra áp lực cơ học khổng lồ, phá hủy trực tiếp các cấu trúc mô não lân cận [27].

Trong thực hành lâm sàng thần kinh học, nguyên lý "Thời gian là Não" (Time is Brain) luôn được coi là kim chỉ nam tối thượng cho mọi chiến lược cấp cứu. Các công trình nghiên cứu hiện đại tiếp tục tái khẳng định tính khốc liệt của nguyên lý này: đối với một ca đột quỵ thiếu máu cục bộ không được tái thông mạch kịp thời, trung bình cứ mỗi phút trôi qua, bệnh nhân sẽ mất đi vĩnh viễn khoảng 1,9 triệu nơ-ron thần kinh, 14 tỷ khớp nối synapse và 12 km sợi trục myelin [28]. Tốc độ tàn phá thần kinh không thể đảo ngược này minh chứng một cách đanh thép rằng, chiến lược y tế tối ưu nhất không nằm ở việc nỗ lực điều trị hậu quả, mà phải dịch chuyển trọng tâm sang tầm soát và dự phòng chủ động. Dựa trên các nghiên cứu dịch tễ quy mô lớn toàn cầu, mạng lưới các yếu tố rủi ro (risk factors) đã được phân tách thành hai nhóm độc lập: nhóm có thể can thiệp điều chỉnh (như tăng huyết áp, đái tháo đường, rối loạn chuyển hóa lipid, lạm dụng thuốc lá, béo phì, lối sống tĩnh tại) và nhóm cố định không thể thay đổi (như yếu tố tuổi tác, giới tính, chủng tộc và tiền sử di truyền) [29].

Sự tương tác đan xen và cộng hưởng của ma trận rủi ro phức tạp này đặt ra nhu cầu vô cùng cấp thiết về các công cụ dự báo biến cố sớm. Trải qua nhiều thập kỷ, y học dự phòng chủ yếu đánh giá nguy cơ dựa trên các thang điểm lâm sàng truyền thống như Framingham Stroke Risk Score (FSRS) hay CHA₂DS₂-VASc [30]. Mặc dù phổ biến, các công cụ này ngày càng bộc lộ nhiều điểm nghẽn cố hữu: chúng vận hành dựa trên giả định mô hình tuyến tính (linear) và chỉ bao quát được một dải hẹp các đặc trưng lâm sàng, từ đó bỏ sót hoàn toàn những mối tương quan

chéo ẩn sâu trong các hồ sơ bệnh án đa chiều [31]. Đây chính là "khoảng trống học thuật" mà các thuật toán Học máy (Machine Learning) có thể giải quyết triệt để. Khác biệt với các phương pháp thống kê cổ điển, Học máy sở hữu năng lực khai phá tính phi tuyến tính (non-linear) mạnh mẽ trong không gian dữ liệu lớn, qua đó mang lại độ nhạy, độ đặc hiệu và năng lực dự báo rủi ro đột quỵ vượt trội hơn hẳn so với các thang điểm Framingham truyền thống [31], [32].

2.2. Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS)

Trong hệ sinh thái y tế kỹ thuật số hiện đại, Hệ thống Hỗ trợ Quyết định Lâm sàng (Clinical Decision Support System - CDSS) được định nghĩa là một cấu trúc công nghệ thông tin y sinh chuyên biệt, được thiết kế nhằm tối ưu hóa các phán quyết và hành động của đội ngũ y tế trong quy trình chăm sóc sức khỏe [33]. Bằng cách thiết lập cơ chế tích hợp đồng bộ giữa dữ liệu đặc trưng riêng biệt của người bệnh và kho tàng tri thức y khoa đã được số hóa, CDSS có khả năng cung cấp các nhắc nhở chủ động (reminders), các khuyến nghị can thiệp dựa trên bằng chứng, hoặc các cảnh báo rủi ro lâm sàng phù hợp theo từng ngữ cảnh thời gian thực cho nhân viên y tế [33]. Sự dịch chuyển mang tính bước ngoặt từ các kiến trúc CDSS truyền thống vận hành dựa trên tập quy tắc cứng nhắc (Rule-based) sang các hệ thống thế hệ mới tích hợp Trí tuệ Nhân tạo (AI) và Học máy (Machine Learning) đã đánh dấu một bước tiến mang tính cách mạng trong y học thực chứng [34].

Các nghiên cứu thực nghiệm giai đoạn 2024–2026 đã chứng minh tính ưu việt vượt trội của mô hình CDSS dựa trên nền tảng Học máy nhờ vào ba năng lực cốt lõi: xử lý không gian đặc trưng đa chiều vô cùng đồ sộ từ hồ sơ bệnh án điện tử, tự động thích ứng học hỏi để liên tục nâng cao độ chính xác khi tiếp nhận các nguồn dữ liệu lâm sàng mới, và khai phá thành công các mối tương quan chéo mang tính phi tuyến tính (non-linear) phức tạp giữa các yếu tố rủi ro âm thầm tích tụ trong cơ thể người bệnh [34], [35]. Khả năng bóc tách các mối quan hệ phi tuyến tính này là một bước đột phá lớn, vượt xa giới hạn phân tích thống kê của con người, giúp phát hiện sớm các biểu hiện bệnh lý mờ nhạt nhất.

Dẫu vậy, việc triển khai rộng rãi các mô hình học máy tiên tiến vào thực tế lâm sàng tại các bệnh viện hiện nay vẫn phải đối mặt với một rào cản bản lề, đó là bản chất "hộp đen" (Black-box) cấu thành từ hệ thống các tham số toán học trừu tượng và không thể tường minh của thuật toán [36]. Trong môi trường y khoa khắt khe—nơi mỗi quyết định can thiệp lâm sàng đều liên quan trực tiếp đến sinh mạng của người bệnh, các nhà chẩn đoán lẫn bệnh nhân không thể trao trọn niềm tin cho một kết quả dự báo phân lớp đơn thuần mà không thể lý giải được cơ chế suy luận và các luận cứ khoa học đằng sau nó [36], [37]. Việc thiếu hụt cơ chế giải thích lý

do dẫn đến sự hoài nghi chính đáng từ giới chuyên môn, cản trở tiến trình thương mại hóa và ứng dụng thực tế của phần mềm. Xuất phát từ thách thức đó, Trí tuệ Nhân tạo có thể giải thích (Explainable AI - XAI) đã chuyển mình từ một nhánh nghiên cứu lý thuyết thuần túy thành một thành phần cốt lõi, bắt buộc phải có trong kiến trúc thượng tầng của các hệ thống CDSS thế hệ mới, đóng vai trò chuyển đổi các phân tích thuật toán phức tạp thành các minh chứng y học minh bạch, trực quan và có thể kiểm chứng được [37].

2.3. So sánh các mô hình

XGBoost (eXtreme Gradient Boosting): Là một kiến trúc học máy kết hợp tiên tiến, được phát triển dựa trên nền tảng tối ưu hóa khung tăng cường gradient (Gradient Boosting Framework). Thuật toán này định hình danh tiếng toàn cầu nhờ tốc độ thực thi vượt trội và khả năng tối ưu hóa hàm mục tiêu cực kỳ chuẩn xác. Bằng việc tích hợp trực tiếp các cơ chế chính quy hóa (regularization) L1 (Lasso) và L2 (Ridge) vào phương trình mục tiêu, XGBoost có khả năng kiểm soát chặt chẽ mức độ phức tạp của các cây quyết định cơ sở, từ đó ngăn chặn hiệu quả hiện tượng quá khớp (overfitting) [38]. Bên cạnh đó, kiến trúc phân chia nhận thức thưa (sparsity-aware split finding) cho phép XGBoost tự động học được hướng đi tối ưu cho các giá trị khuyết thiếu (missing values) mà không cần nội suy thủ công. Điều này khiến thuật toán trở thành một công cụ cực kỳ mạnh mẽ và được ưu tiên hàng đầu trong việc phân tích các hồ sơ bệnh án điện tử dạng bảng [38], [39].

Bản chất toán học cốt lõi của XGBoost nằm ở việc tối ưu hóa hàm mục tiêu có chứa thành phần chính quy hóa (Regularization) để kiểm soát độ phức tạp của mô hình:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Trong đó,

- l là hàm mất mát đo lường sai số dự báo
- $\Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|_2^2$ là thành phần phạt độ phức tạp của cây (với T là số lá, w là trọng số lá).

LightGBM (Light Gradient Boosting Machine): Là một biến thể gradient boosting mang tính đột phá do Microsoft phát triển, vận hành dựa trên cơ chế phát triển cây theo lá (leaf-wise growth) thay vì theo mức (level-wise) như các thuật toán truyền thống. Điểm làm nên sức mạnh cốt lõi của LightGBM là việc ứng dụng hai kỹ thuật tiên tiến: Lấy mẫu một phía dựa trên Gradient (GOSS - Gradient-based One-Side Sampling) và Nhóm đặc trưng độc quyền (EFB - Exclusive Feature Bundling) [40]. Các cơ chế này giúp mô hình tự động loại bỏ các mẫu dữ liệu có gradient nhỏ và nén các đặc trưng rời rạc, giúp giảm thiểu không gian tính toán mà không làm suy giảm độ chính xác định lượng. Nhờ vậy, LightGBM cải thiện tốc độ huấn luyện theo cấp số nhân, đặc biệt tỏ ra ưu việt khi phải xử lý các bộ dữ liệu y sinh có quy mô lớn và không gian đặc trưng đa chiều [40].

CatBoost (Categorical Boosting): Là một hệ thống gradient boosting thế hệ mới do Yandex nghiên cứu và phát triển, mang lại giải pháp kỹ thuật triệt để cho bài toán xử lý các biến phân loại (categorical features). Điểm khác biệt của CatBoost nằm ở khả năng tự động xử lý trực tiếp các đặc trưng chuỗi hoặc phân loại mà không đòi hỏi các kỹ thuật tiền xử lý phức tạp (như One-hot Encoding), giúp tiết kiệm dung lượng bộ nhớ và ngăn chặn sự bùng nổ chiều dữ liệu [41]. Thông qua cơ chế tăng cường có trật tự (ordered boosting) và việc sử dụng cấu trúc cây quyết định đối xứng (oblivious trees), CatBoost giải quyết thành công độ chệch dự báo (prediction shift) và triệt tiêu hoàn toàn hiện tượng rò rỉ mục tiêu (target leakage) [42]. Đặc tính kỹ thuật này biến CatBoost trở thành một kiến trúc cực kỳ bền vững và tương thích hoàn hảo với dữ liệu y khoa—nơi có mật độ dày đặc các biến phân loại rời rạc như giới tính, tình trạng hút thuốc, hay tiền sử bệnh lý nền [41], [42].

2.4 Bộ dữ liệu “Brain stroke prediction dataset” và tiền xử lý dữ liệu y tế

Bộ dữ liệu Brain stroke prediction dataset được sử dụng trong nghiên cứu này bắt nguồn từ kho lưu trữ số hóa của các hệ thống giám sát sức khỏe quy mô lớn, tiêu biểu là nền tảng khảo sát của Trung tâm Kiểm soát và Phòng ngừa Dịch bệnh Hoa Kỳ (CDC). Đây được xem là một trong những mạng lưới giám sát dịch tễ học qua điện thoại đồ sộ nhất thế giới, thiết lập hồ sơ sức khỏe định kỳ cho hàng trăm nghìn người trưởng thành nhằm theo dõi các yếu tố rủi ro hành vi và bệnh lý nền

[43]. Phục vụ cho bài toán tối ưu hóa học máy, nghiên cứu trích xuất một không gian mẫu chuẩn hóa bao gồm 11 đặc trưng cốt lõi. Các đặc trưng này là sự kết hợp đa chiều giữa yếu tố nhân khẩu học, chỉ số sinh lý lâm sàng và thói quen sinh hoạt, được cấu trúc chi tiết như trong Bảng 2.1 dưới đây:

Bảng 2.1 Bảng từ điển dữ liệu (Data Dictionary) của tập dữ liệu dự báo đột quỵ

Đặc trưng	Mô tả	Loại dữ liệu
stroke	Bệnh nhân có bị đột quỵ hay không (0 = Không, 1 = Có) - <i>Biến mục tiêu</i>	Nhị phân
gender	Giới tính của bệnh nhân (Male / Female)	Phân loại
age	Độ tuổi của bệnh nhân	Liên tục
hypertension	Tình trạng cao huyết áp (0 = Không, 1 = Có)	Nhị phân
heart_disease	Tình trạng bệnh tim mạch (0 = Không, 1 = Có)	Nhị phân
ever_married	Từng kết hôn hay chưa (Yes / No)	Nhị phân
work_type	Loại hình công việc (Private, Self-employed, Govt_job, children...)	Phân loại
Residence_type	Môi trường sinh sống (Urban = Thành thị, Rural = Nông thôn)	Nhị phân
avg_glucose_level	Chỉ số đường huyết trung bình trong máu	Liên tục
bmi	Chỉ số khối cơ thể (Body Mass Index)	Liên tục
smoking_status	Tình trạng hút thuốc lá (never smoked, formerly smoked, smokes, Unknown)	Phân loại

Trong các dự án khai phá dữ liệu y sinh, quy trình kỹ nghệ dữ liệu (Data Engineering) và tiền xử lý (Data Preprocessing) đóng vai trò nền tảng, quyết định trực tiếp đến độ hội tụ và độ tin cậy của mô hình dự báo [44]. Chuỗi thao tác tiền xử lý được thiết lập nghiêm ngặt trong đề tài bao gồm: kiểm định và nội suy các giá trị khuyết thiếu (missing value imputation), cô lập các điểm dữ liệu ngoại lai (outliers detection) để tránh gây nhiễu thuật toán, thực hiện mã hóa One-hot cho các biến phân loại, chuẩn hóa thang đo cho các đặc trưng liên tục, và phân tích ma trận tương quan (Correlation Matrix) nhằm loại bỏ các biến dư thừa gây bùng nổ chiều không gian.

Đặc biệt, đặc thù lớn nhất và cũng là rào cản kỹ thuật nghiêm trọng nhất của bộ dữ liệu này nằm ở sự mất cân bằng phân phối lớp cực đoan (Extreme Class Imbalance) [45]. Trong các quần thể khảo sát tự nhiên, tỷ lệ bệnh nhân có chẩn đoán dương tính với đột quỵ (label = 1) thường vô cùng nhỏ, chỉ dao động ở mức 2% đến 3% tổng không gian mẫu [45]. Nếu tiến hành huấn luyện trực tiếp trên tập dữ liệu thô này, các thuật toán học máy sẽ rơi vào bẫy "ảo giác độ chính xác" (Accuracy Paradox) – mô hình có xu hướng dự đoán tất cả các ca đều là âm tính (không đột quỵ) để đạt độ chính xác giả tạo 97%. Hệ lụy của việc này là hệ thống sẽ bỏ lọt hoàn toàn các bệnh nhân đang đối mặt với rủi ro tử vong thực sự. Do đó, việc ứng dụng các chiến lược can thiệp tái lấy mẫu ở cấp độ dữ liệu (như thuật toán SMOTE) là yêu cầu bắt buộc để ép buộc mô hình phải "quan tâm" đến nhóm thiểu số, từ đó thiết lập một hệ thống sàng lọc y tế an toàn và có độ nhạy cao.


2.5 Kỹ thuật xử lý mất cân bằng dữ liệu bằng SMOTE

Hiện tượng mất cân bằng phân phối lớp (Class Imbalance) được xem là một trong những rào cản kỹ thuật kinh điển và nghiêm trọng nhất trong không gian phân tích dữ liệu y tế số. Khi kích thước không gian mẫu của lớp dương tính (bệnh nhân mắc bệnh) chiếm tỷ trọng quá thấp so với quần thể chung, hàm mục tiêu của các thuật toán học máy thông thường có xu hướng bị thiên lệch (biased) nặng nề về phía lớp đa số [46]. Hệ lụy của tình trạng xáo trộn phân phối này là mô hình sẽ tối ưu hóa sai lệch, dẫn đến việc gia tăng tỷ lệ bỏ sót các ca bệnh thực tế trong môi trường lâm sàng (False Negatives)—một sai lầm hệ thống có thể gây ra những hậu quả tàn

khắc đối với tính mạng người bệnh và làm mất đi cửa sổ vàng điều trị [46]. Để giải quyết triệt để điểm nghẽn này ngay từ tầng dữ liệu, thuật toán SMOTE (Synthetic Minority Over-sampling Technique) đã được nghiên cứu và ứng dụng như một giải pháp tăng cường dữ liệu (Data Augmentation) bản lề cho lớp thiểu số. Thay vì áp dụng phương pháp sao chép cơ học các điểm dữ liệu có sẵn (Random Over-sampling) dễ dẫn đến hiện tượng quá khớp (overfitting), SMOTE thiết lập một cơ chế toán học dựa trên nguyên lý nội suy hình học phi tuyến tính [47]. Quy trình vận hành của SMOTE bắt đầu bằng việc thiết lập một điểm dữ liệu bất kỳ thuộc nhóm thiểu số, tìm kiếm k láng giềng gần nhất (k -Nearest Neighbors) của nó trong không gian đặc trưng đa chiều, và tiến hành khởi tạo ngẫu nhiên các véc-tơ mẫu tổng hợp (synthetic samples) nằm dọc theo phân đoạn tuyến tính nối liền điểm gốc với các láng giềng được chọn [47]. Cơ chế này mang lại độ phong phú và đa dạng sinh học cao cho dữ liệu tăng cường, giúp mô hình AI bao quát tốt hơn các mô hình bệnh lý phức tạp.

Nhằm nâng cao hơn nữa độ sắc nét của đường ranh giới quyết định, đề tài quyết định lựa chọn triển khai toán tử nâng cao Borderline-SMOTE—một biến thể cải tiến mang tính chiến lược của cấu trúc SMOTE nguyên bản. Thay vì phân bổ mẫu tổng hợp một cách đồng đều và mù quáng trên toàn bộ không gian hình học, Borderline-SMOTE tập trung toàn bộ tài nguyên tính toán để độc quyền sinh mẫu tại vùng biên giới quyết định (Borderline Region) đan xen giữa hai lớp nhãn [48]. Theo lý thuyết học máy lâm sàng, các điểm dữ liệu nằm sát vùng ranh giới này thường có độ nhiễu cao, cực kỳ khó phân tách nhưng lại mang hàm lượng thông tin (Information Value) lớn nhất để huấn luyện các hàm phân lớp sâu [48]. Việc tích hợp giải pháp Borderline-SMOTE vào quy trình tiền xử lý của đề tài không chỉ tối ưu hóa năng lực bắt bệnh (Recall) của engine AI, mà còn đảm bảo khả năng kiểm soát chặt chẽ độ toàn vẹn của dữ liệu sinh ra, triệt tiêu hoàn toàn hiện tượng chồng lấn dữ liệu (Class Overlapping) thường gặp trong dữ liệu y sinh dạng bảng [47], [48].

Synthetic Minority Oversampling Technique



Hình 2.1 Minh họa không gian đặc trưng và cơ chế nội suy mẫu nhân tạo của thuật toán SMOTE.

Công thức nội suy sinh mẫu tổng hợp của SMOTE được biểu diễn như sau:

$$x_{\text{new}} = x_i + \lambda \cdot (x_{z_i} - x_i)$$

Trong đó,

- x_{new} là dữ liệu mới được sinh ra, x_i là mẫu thiểu số đang xét ở vùng biên,
- x_{z_i} là một trong k láng giềng gần nhất
- λ là một số ngẫu nhiên trong khoảng $[0, 1]$

2.6 Cơ chế giải thích Trí tuệ Nhân tạo minh bạch với framework SHAP

Nhằm dỡ bỏ hoàn toàn rào cản "hộp đen" của các mô hình học máy nâng cao và thiết lập khung pháp lý - kỹ thuật minh bạch cho các quyết định lâm sàng, framework SHAP (SHapley Additive exPlanations) đã được nghiên cứu và tích hợp như một giải pháp cốt lõi. SHAP là một phương pháp luận toán học vững chắc được xây dựng dựa trên nền tảng của lý thuyết trò chơi hợp tác (Cooperative Game Theory), cụ thể là việc kế thừa và tối ưu hóa khái niệm giá trị Shapley (Shapley values) [49]. Trong không gian học máy, thuật toán thiết lập một "trò chơi" tương tác, nơi các đặc trưng đầu vào (các chỉ số lâm sàng của bệnh nhân) đóng vai trò là các người chơi (players), phối hợp cùng nhau để tạo ra tổng giải thưởng chính là giá

trị dự báo xác suất của mô hình (output prediction) [49]. Ý tưởng trung tâm của SHAP là tính toán và phân bổ một cách công bằng phần thưởng này bằng cách định lượng chính xác "đóng góp biên" (marginal contribution) của từng đặc trưng đơn lẻ vào kết quả dự báo tổng thể, tuân thủ nghiêm ngặt các đặc tính toán học bản lề bao gồm: tính hiệu quả (efficiency), tính đối xứng (symmetry), tính đơn điệu (monotonicity) và gán đặc trưng cộng tính (additive feature attribution) [49], [50].

Dựa trên cấu trúc tính toán tối ưu, framework SHAP cung cấp hai tầng cấp độ giải thích trực quan, đáp ứng trọn vẹn yêu cầu kiểm định chuyên môn của các nhà lâm sàng:

- **Khả năng giải thích toàn cục (Global Explainability):** Cung cấp một góc nhìn vĩ mô (macro view) về toàn bộ cơ chế vận hành của mô hình AI trên toàn bộ quần thể dữ liệu nghiên cứu. Thông qua việc tổng hợp giá trị SHAP tuyệt đối của tất cả các mẫu, hệ thống thiết lập bảng phân tầng mức độ quan trọng và xu hướng tác động của các biến số y tế, thường được trực quan hóa sinh động thông qua biểu đồ SHAP Summary Plot (Beeswarm) [50]. Lớp giải thích này giúp các nhà nghiên cứu dịch tễ học nhận diện được đâu là các tác nhân mang tính định hình cốt lõi đối với xu hướng phát bệnh đột quy ở quy mô cộng đồng.
- **Khả năng giải thích cục bộ (Local Explainability):** Cung cấp một góc nhìn vi mô (micro view) cá nhân hóa tuyệt đối cho từng ca bệnh riêng lẻ. Tại cấp độ này, SHAP bóc tách phương trình dự báo phức tạp thành một biểu đồ đóng góp tuyến tính dạng SHAP Waterfall Plot hoặc Force Plot [51]. Biểu đồ này chỉ rõ mối quan hệ dịch chuyển xác suất từ mức nền trung bình của quần thể (base value) đến mức rủi ro thực tế của riêng bệnh nhân đó, giúp bác sĩ đọc vị chính xác nguyên nhân gốc rễ dẫn đến cảnh báo đỏ của hệ thống.

Trong kiến trúc của một Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS) chuyên sâu về tai biến mạch máu não, sự hiện diện của SHAP tạo nên một bước ngoặt về tính thực tiễn và tính nhân văn của công nghệ. Trực quan hóa SHAP cho phép các bác sĩ quan sát rõ ràng cơ chế giằng co giữa hai lực đối nghịch: các yếu tố đẩy cao phổ rủi ro của bệnh nhân (giá trị SHAP dương, hiển thị bằng các vector

màu đỏ) và các đặc trưng mang tính chất bảo vệ, giảm thiểu nguy cơ (giá trị SHAP âm, hiển thị bằng các vector màu xanh) [51], [52]. Sự minh bạch hóa này chuyển đổi AI từ một công cụ phân loại mù quáng thành một trợ lý số thông minh, hỗ trợ bác sĩ thiết lập các phác đồ điều trị can thiệp có mục tiêu, có trọng điểm và đạt hiệu suất cao tối đa [52]. Ví dụ, khi hệ thống phát cảnh báo nguy cơ đột quỵ cao cho một bệnh nhân, nếu biểu đồ SHAP chỉ ra chỉ số đường huyết (avg_glucose_level) có trọng số đóng góp dương vượt trội so với chỉ số khối cơ thể (bmi), bác sĩ sẽ lập tức tập trung ưu tiên kiểm soát lâm sàng đái tháo đường thay vì ép bệnh nhân thực hiện các lộ trình giảm cân cực đoan.

Giá trị đóng góp biên (Shapley value) của một đặc trưng i được định nghĩa bằng phương trình toán học sau:

$$\Phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Trong đó:

- Φ_i : Giá trị Shapley của đặc trưng i . Đây là kết quả định lượng cuối cùng thể hiện mức độ đóng góp (tầm quan trọng) của biến số thứ i vào kết quả dự báo của mô hình.
- N : Tập hợp chứa tất cả các đặc trưng (features) đầu vào của mô hình (ví dụ: tuổi tác, huyết áp, lượng đường trong máu...).
- $|N|$: Tổng số lượng các đặc trưng có trong tập N .
- S : Một tập hợp con (subset) bất kỳ chứa các đặc trưng tham gia vào mô hình dự báo, nhưng hoàn toàn không bao gồm đặc trưng i đang được xét ($S \subseteq N \setminus \{i\}$).
- $|S|$: Số lượng các đặc trưng hiện có trong tập hợp con S .
- $v(S)$: Kết quả dự báo của mô hình khi chỉ có sự tham gia của các đặc trưng nằm trong tập S .
- $v(S \cup \{i\})$: Kết quả dự báo của mô hình khi bổ sung thêm đặc trưng i vào tập hợp

S.

- $[v(SU\{i\}) - v(S)]$: Giá trị đóng góp biên (Marginal Contribution). Đại lượng này đo lường sự thay đổi của kết quả dự báo khi có sự xuất hiện thêm của đặc trưng i .
- $[v(SU\{i\}) - v(S)]$: Trọng số tổ hợp (Weighting factor). Phân số này tính toán xác suất xuất hiện của tập hợp S trong tất cả các hoán vị có thể có của các đặc trưng. Nó đóng vai trò lấy trung bình các đóng góp biên, đảm bảo việc phân bổ tầm quan trọng cho đặc trưng i là tuyệt đối công bằng và độc lập với thứ tự đưa các biến vào mô hình.

2.7 Các độ đo đánh giá mô hình phân loại y tế

Trong bối cảnh các bài toán chẩn đoán và dự báo y khoa đối mặt với tình trạng mất cân bằng phân phối lớp cực đoan (Class Imbalance), Độ chính xác tổng thể (Accuracy) đã được chứng minh là một thước đo mang tính "ảo giác" và thiếu tin cậy. Nguyên nhân xuất phát từ việc các hàm phân lớp có xu hướng hội tụ về lớp đa số (không mắc bệnh), dẫn đến một tỷ lệ dự báo chính xác giả tạo rất cao nhưng lại hoàn toàn vô giá trị trong việc nhận diện bệnh lý [53]. Để đánh giá hiệu năng mô hình một cách toàn diện và phản ánh đúng thực tiễn lâm sàng, các nghiên cứu dịch tễ học tính toán hiện đại bắt buộc phải sử dụng một hệ thống các độ đo chuyên sâu hơn. Hệ thống này bao gồm: Độ xác thực (Precision - tỷ lệ chẩn đoán đúng trên tổng số ca được mô hình cảnh báo dương tính), Độ nhạy (Recall/Sensitivity - năng lực phát hiện và không bỏ sót các ca bệnh thực sự), Điểm F1 (F1-Score - trung bình điều hòa giúp cân bằng sự đánh đổi toán học giữa Precision và Recall), và Diện tích dưới đường cong đặc trưng hoạt động (AUC-ROC - thước đo định lượng khả năng phân tách ranh giới tính giữa hai quần thể bệnh lý và khỏe mạnh) [54].

Đặc biệt, trong triết lý của y tế dự phòng và tầm soát rủi ro đột quỵ não, Độ nhạy (Recall/Sensitivity) luôn được đặt lên hàng đầu như một ưu tiên mang tính sinh tử. Xét về mặt hệ lụy y khoa, sai lầm phân loại loại II (False Negatives - mô hình dự báo an toàn nhưng thực chất bệnh nhân đang mang rủi ro tiềm ẩn) mang lại hậu quả lâm sàng khốc liệt và đánh đổi bằng chính sinh mạng con người. Trong khi

đó, sai lầm phân loại loại I (False Positives - cảnh báo nhầm và yêu cầu xét nghiệm thêm) dù gây ra đôi chút bất tiện và lãng phí tài nguyên, nhưng hoàn toàn có thể kiểm soát được trong quy trình tái khám [54], [55].

Kế thừa quan điểm học thuật này, chiến lược tối ưu hóa hàm mục tiêu của khóa luận được thiết lập theo định hướng rõ ràng: cấu hình thuật toán để tối đa hóa Recall nhằm thiết lập một "mạng lưới an toàn" (safety net) tuyệt đối cho người bệnh, đồng thời tinh chỉnh ngưỡng quyết định (Threshold Tuning) để duy trì Precision ở ngưỡng khả thi. Các chỉ số F1-Score và AUC-ROC được ứng dụng làm hai thước đo tổng hợp cốt lõi để đối chiếu chéo, đảm bảo model đạt được trạng thái ổn định, mạnh mẽ và an toàn nhất trước khi triển khai vào môi trường y tế thực tế [53], [55].

Bảng 2.2 Ma trận nhầm lẫn (Confusion Matrix)

Lớp thực tế \ Lớp dự báo	Dự báo Dương tính (Mắc bệnh)	Dự báo Âm tính (Không bệnh)
Thực tế Dương tính	True Positive (TP)	False Negative (FN) - Bỏ sót bệnh
Thực tế Âm tính	False Positive (FP) - Cảnh báo nhầm	True Negative (TN)

Dựa trên Ma trận nhầm lẫn, các độ đo cốt lõi được tính bằng công thức:

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F1_Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

CHƯƠNG 3

PHÂN TÍCH THIẾT KẾ VÀ TRIỂN KHAI HỆ THỐNG

3.1. Mô tả tổng quan hệ thống

Hướng tới mục tiêu xây dựng một phần mềm có khả năng mở rộng dễ dàng và hoạt động ổn định khi triển khai thực tế tại các cơ sở y tế, kiến trúc của Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS) trong đề tài được thiết kế theo mô hình phân lớp (Tiered Architecture). Việc chia nhỏ hệ thống thành các module độc lập không chỉ giúp quy trình quản lý code thuận tiện hơn mà còn đảm bảo sự phối hợp nhịp nhàng giữa các tiến trình. Về cơ bản, toàn bộ hệ thống được cấu thành từ ba lớp lõi như sau:

Thứ nhất là Lớp tiền xử lý và huấn luyện (Offline Data & Model Pipeline). Đây có thể xem là phần "hậu trường" (backend) đảm nhận toàn bộ khối lượng tính toán nặng nhất của dự án. Cụ thể, tiến trình này sẽ đọc dữ liệu từ các tệp hồ sơ bệnh án, thực hiện các bước dọn dẹp, xử lý nhiễu và trích chọn đặc trưng (feature engineering). Đặc biệt, lớp này tích hợp thuật toán Borderline-SMOTE để giải quyết tình trạng mất cân bằng dữ liệu y tế, tạo tiền đề cho việc huấn luyện và dò tìm bộ siêu tham số (hyperparameter tuning) tối ưu nhất cho các mô hình học máy.

Thứ hai là Lớp suy luận và giải thích AI (Inference & XAI Engine). Nếu xem kiến trúc này là một cơ thể thì đây chính là "bộ não" điều phối. Luồng hoạt động diễn ra theo thời gian thực (real-time): ngay khi nhận được các thông tin sức khỏe của một bệnh nhân mới, hệ thống sẽ lập tức gọi các tệp mô hình đã được huấn luyện và lưu trữ sẵn (serialized models) để tính toán ra tỷ lệ phần trăm nguy cơ đột quỵ. Cùng lúc đó, cơ chế TreeExplainer từ thư viện SHAP cũng được kích hoạt để phân tích ngược lại phương trình dự đoán, qua đó chỉ ra chính xác mức độ tác động của từng chỉ số sinh lý (như đường huyết, huyết áp, tuổi tác...) đến kết quả cuối cùng.


Cuối cùng là Lớp giao diện ứng dụng (Web Application Layer). Đây là lớp bề mặt (frontend) – nơi các y bác sĩ sẽ thao tác và tương tác trực tiếp với hệ thống. Lớp này được xây dựng với các biểu mẫu nhập liệu rõ ràng, có tích hợp chức năng

kiểm tra tính hợp lệ của dữ liệu đầu vào (validation). Giao diện sẽ giao tiếp với lớp suy luận (Inference Engine) thông qua các API nội bộ. Mọi kết quả phân tầng mức độ rủi ro cũng như các biểu đồ giải thích nguyên nhân của SHAP sẽ được hiển thị trực quan thông qua các Dashboard tương tác, giúp bác sĩ nắm bắt tình trạng bệnh nhân một cách nhanh chóng và đáng tin cậy.

Bảng 3.1 Thành phần công nghệ và vai trò chức năng trong kiến trúc CDSS

Thành phần hệ thống	Nền tảng công nghệ áp dụng	Vai trò chức năng trong kiến trúc
Data Pipeline	Ngôn ngữ Python, Thư viện Pandas, Scikit-learn	Thực thi quy trình ETL (Extract-Transform-Load), làm sạch dữ liệu, xử lý giá trị ngoại lai, mã hóa biến phân loại và kỹ nghệ đặc trưng trên bộ dữ liệu nền tảng <i>Brain Stroke Dataset</i> .
SMOTE Engine	Framework imbalanced-learn	Triển khai toán tử nâng cao Borderline-SMOTE trên tập dữ liệu huấn luyện offline nhằm tái thiết lập phân phối cân bằng giữa hai lớp nhãn, tối ưu hóa độ nhạy cho mô hình.
Predictive Models	Thuật toán XGBoost	Đóng vai trò là các công cụ phân loại lỗi, thực hiện tính toán phi tuyến tính trên không gian dữ liệu đa chiều để đưa ra phân tầng xác suất rủi ro đột quỵ.
XAI Engine	Thư viện SHAP (SHapley Additive exPlanations)	Tường minh hóa cơ chế "hộp đen" của thuật toán; tính toán giá trị Shapley để định lượng công lao đóng góp của từng đặc trưng lâm sàng ở cả cấp độ toàn cục và cá nhân hóa.
Web Backend & UI	Framework Streamlit	Xây dựng kiến trúc máy chủ ứng dụng gọn nhẹ, quản lý luồng trạng thái dữ liệu (state management) và sinh giao diện người dùng tương tác động

Thành phần hệ thống	Nền tảng công nghệ áp dụng	Vai trò chức năng trong kiến trúc
		(dynamic UI).
Data Visualization	Thư viện Matplotlib, Plotly	Trực quan hóa các chỉ số hiệu năng hệ thống, vẽ biểu đồ phân phối dữ liệu khám phá và xuất các đồ thị thác nước (Waterfall), lực lượng (Force Plot) của SHAP.



Hình 3.1 Quy trình phát hiện khuôn mặt, căn chỉnh và trích xuất embedding trong hệ thống AuEdu.

3.2 Phân tích tác nhân và yêu cầu hệ thống

3.2.1. Các tác nhân tương tác với hệ thống (Actors)

Phần mềm được cấu trúc để phục vụ cho hai nhóm đối tượng người dùng cốt lõi với các phân quyền và mục đích sử dụng hoàn toàn riêng biệt:

- **Bác sĩ và Nhân viên y tế (Tác nhân lâm sàng):** Là nhóm người dùng trực tiếp thao tác trong quy trình khám chữa bệnh. Tác nhân này có quyền sử dụng biểu mẫu để nhập chỉ số sức khỏe của bệnh nhân, tiếp nhận kết quả phân tầng nguy

cơ đột quy, đọc các biểu đồ giải thích SHAP được cá nhân hóa cho từng ca bệnh, và quản lý, sàng lọc danh sách các bệnh nhân nằm trong nhóm rủi ro cao để kịp thời đưa ra phác đồ can thiệp.

- **Nhà nghiên cứu và Quản trị viên (Tác nhân hệ thống):** Nhóm đối tượng này tập trung vào khía cạnh kỹ thuật và vận hành. Họ có quyền truy cập vào các bảng thống kê để theo dõi các chỉ số đo lường hiệu năng của thuật toán, phân tích bức tranh tổng quan về mức độ ảnh hưởng của các biến số y tế thông qua cơ chế SHAP toàn cục, đồng thời thực hiện các thiết lập và quản lý cấu hình hoạt động của toàn bộ phần mềm.

3.2.2. Các yêu cầu chức năng trọng tâm (Functional Requirements)

Để hệ thống vận hành đúng mục tiêu đề ra, các tính năng cốt lõi cần phải được hiện thực hóa bao gồm:

1. **Chức năng thu thập dữ liệu đầu vào:** Hệ thống cung cấp giao diện cho phép nhập liệu và kiểm tra tính hợp lệ của 22 thuộc tính đặc trưng, bao gồm các chỉ số lâm sàng y khoa và các hành vi thói quen ảnh hưởng đến sức khỏe của bệnh nhân.
2. **Chức năng phân tầng nguy cơ rủi ro:** Ứng dụng thuật toán để tính toán ra xác suất xảy ra biến cố, từ đó tự động phân loại tình trạng bệnh nhân vào 3 nhóm cụ thể: nhóm nguy cơ Thấp (xác suất $< 20\%$), nhóm nguy cơ Trung bình (xác suất từ 20% đến 50%), và nhóm nguy cơ Cao (xác suất $> 50\%$).
3. **Chức năng giải thích toàn cục (SHAP Global Explanation):** Khai thác thư viện XAI để trực quan hóa và xuất ra biểu đồ xếp hạng tầm quan trọng của các đặc trưng, giúp người dùng nắm được các yếu tố nào có tác động mạnh nhất đến xu hướng dự báo chung của thuật toán.
4. **Chức năng giải thích cục bộ (SHAP Local Explanation):** Sinh tự động biểu đồ Waterfall (đồ thị thác nước) cho từng ca bệnh riêng biệt, thể hiện rõ ràng các chỉ số sinh lý cụ thể của bệnh nhân đó đang kéo xác suất dự đoán tăng lên hay giảm xuống như thế nào.
5. **Chức năng đánh giá và giám sát hiệu năng mô hình:** Hệ thống cung cấp các module thống kê, vẽ biểu đồ đường cong ROC và tính toán các chỉ số đo lường chất lượng phân loại của riêng mô hình XGBoost (như độ nhạy Recall, điểm F1-Score, độ chính xác Accuracy) qua các đợt kiểm thử hoặc thay đổi ngưỡng quyết định (Threshold), nhằm đảm bảo tính ổn định tối đa của thuật toán trước khi đưa ra khuyến nghị lâm sàng.

3.3 Quy trình tiền xử lý và tăng cường dữ liệu

Quy trình phân tích được bắt đầu bằng việc đọc và đánh giá chất lượng của bộ dữ liệu nền tảng "Full-filled Brain Stroke Dataset". Bộ dữ liệu này cung cấp một không gian mẫu chuẩn hóa bao gồm 11 trường đặc trưng cốt lõi (như tuổi tác, giới tính, tình trạng tăng huyết áp, bệnh tim mạch, mức đường huyết, chỉ số BMI...) và tổng cộng 4.981 hồ sơ bệnh án điện tử độc lập.

Điểm ưu việt của bộ dữ liệu này là toàn bộ không gian mẫu đã được tiền xử lý toàn vẹn (full-filled), khắc phục triệt để độ nhiễu và sự khuyết thiếu thông tin. Do đó, thay vì phải xử lý hoặc nội suy các ô trống, quy trình tiền xử lý tập trung vào các kỹ thuật làm sạch chuyên sâu hơn, bao gồm việc chuẩn hóa cấu trúc trường dữ liệu, cô lập các điểm dữ liệu ngoại lai (outliers) để tránh gây nhiễu thuật toán, thực hiện mã hóa One-hot (One-hot Encoding) cho các biến phân loại, và chuẩn hóa thang đo cho các đặc trưng liên tục.

Một thách thức rất lớn của đề án đã bộc lộ ở bước khám phá nhãn dự đoán (Target Variable): sự mất cân bằng phân phối lớp cực đoan (Extreme Class Imbalance). Trong toàn bộ tập dữ liệu y tế này, chỉ có vỏn vẹn 248 ca dương tính có tiền sử đột quỵ (chiếm khoảng 4,98%), bị áp đảo hoàn toàn bởi quần thể âm tính khỏe mạnh. Sự chênh lệch tỷ lệ này là một rào cản kỹ thuật nghiêm trọng, bởi nếu đưa trực tiếp dữ liệu thô vào thuật toán, mô hình sẽ rơi vào bẫy "ảo giác độ chính xác" (Accuracy Paradox) – hệ thống sẽ có xu hướng dự đoán tất cả là an toàn, thiên vị lớp đa số và bỏ lọt hoàn toàn các bệnh nhân đang đối mặt với rủi ro tử vong thực sự.

Để giải quyết triệt để điểm nghẽn này, quy trình xử lý được thiết kế tuân thủ nghiêm ngặt các nguyên tắc học máy:

- **Phân chia tập dữ liệu:** Đầu tiên, bộ dữ liệu chuẩn hóa được chia ngẫu nhiên thành tập huấn luyện (Train set) và tập kiểm thử (Test set) theo tỷ lệ 80/20. Quá trình này sử dụng kỹ thuật phân tầng (stratified split) để đảm bảo phân phối nhãn âm tính và dương tính được duy trì đồng đều giữa các tập. Kết quả trích xuất được 3.984 bản ghi cho tập huấn luyện (chứa 198 ca đột quỵ) và 997 bản ghi cho tập kiểm thử.

- **Tăng cường dữ liệu:** Ngay sau đó, thuật toán sinh mẫu nhân tạo thông minh Borderline-SMOTE được cấu hình để can thiệp. Điểm mấu chốt ở đây là kỹ thuật SMOTE chỉ được áp dụng độc lập và duy nhất trên tập huấn luyện. Việc cô lập bước sinh dữ liệu giả này là bắt buộc để ngăn chặn tuyệt đối hiện tượng "rò rỉ dữ liệu" (Data Leakage) sang tập kiểm thử. Nhờ sự can thiệp này, số lượng mẫu trong tập huấn luyện được mở rộng lên 7.572 bản ghi, đạt tỷ lệ cân bằng tuyệt đối 1:1 (với 3.786 ca dương tính và 3.786 ca âm tính). Điều này tạo ra một môi trường dữ liệu lý tưởng để thuật toán XGBoost có thể nhận diện khách quan mọi quy luật rủi ro ẩn sâu bên trong mà không bị thiên lệch.

3.4 Huấn luyện và tinh chỉnh siêu tham số mô hình XGBoost

Sau khi hoàn tất quá trình dọn dẹp và cân bằng dữ liệu, thuật toán XGBoost chính thức được đưa vào huấn luyện. Thay vì gán các tham số theo cảm tính hoặc thử nghiệm thủ công (Grid Search) mất nhiều thời gian, quy trình tinh chỉnh siêu tham số (hyperparameter tuning) của đồ án được thực hiện hoàn toàn tự động thông qua thư viện Optuna (dựa trên phương pháp Tối ưu hóa Bayes - Bayesian Optimization).

Để đảm bảo kết quả đánh giá là khách quan và không bị thiên lệch, quá trình dò tìm tham số được kết hợp chặt chẽ với chiến lược kiểm chứng chéo 5 phần (5-fold Cross-Validation). Hàm mục tiêu được thiết lập cho Optuna là tìm ra tổ hợp tham số giúp tối đa hóa chỉ số AUC-ROC. Đặc biệt, để ngăn chặn tình trạng mô hình bị "học vẹt" (overfitting) và giảm thiểu thời gian tính toán dư thừa, cơ chế dừng sớm (early stopping) đã được kích hoạt xuyên suốt quá trình chạy.

Bộ cấu hình tối ưu nhất mà Optuna tìm ra cho thuật toán XGBoost được tổng hợp chi tiết trong

Bảng 3.2 Các siêu tham số tốt nhất cho mô hình XGBoost

Tên siêu tham số	Cấu hình tốt nhất	Ý nghĩa trong thực nghiệm	Tên siêu tham số
n_estimators	500	Số lượng cây quyết định tối đa được xây dựng trong quá trình boosting.	n_estimators
max_depth	6	Độ sâu tối đa của mỗi cây, mức 6 giúp mô hình đủ độ phức tạp nhưng không bị quá khớp.	max_depth
learning_rate	0.05	Tốc độ học của thuật toán, được tinh chỉnh ở mức thấp để mô hình hội tụ từ từ và ổn định.	learning_rate
subsample	0.8	Mô hình sẽ lấy mẫu ngẫu nhiên 80% dữ liệu huấn luyện để xây dựng mỗi cây, giúp tăng tính tổng quát hóa.	subsample
reg_alpha (L1)	0.1	Trọng số phạt L1, giúp loại bỏ các đặc trưng nhiễu, không quan trọng.	reg_alpha (L1)
reg_lambda (L2)	1.0	Trọng số phạt L2, giúp làm mượt các dự đoán và kiểm soát sự phát triển quá mức	reg_lambda (L2)

Tên siêu tham số	Cấu hình tốt nhất	Ý nghĩa trong thực nghiệm	Tên siêu tham số
		của cây.	

3.5 Tích hợp SHAP XAI vào pipeline dự báo

Sau khi mô hình phân loại được huấn luyện và lưu trữ thành công, thư viện SHAP (SHapley Additive exPlanations) được nhúng trực tiếp vào quy trình xử lý nhằm thực hiện nhiệm vụ tường minh hóa kết quả. Vì giải pháp lõi của đồ án tập trung vào các cấu trúc thuật toán dạng cây quyết định (tiêu biểu là XGBoost), hệ thống khởi tạo bộ giải thích TreeExplainer để tối ưu hóa hiệu suất toán học và tốc độ trích xuất dữ liệu.

Quy trình vận hành từ lúc hệ thống tiếp nhận thông tin bệnh nhân đến khi xuất kết quả giải thích cá nhân hóa trên giao diện ứng dụng được thực thi theo thời gian thực (real-time) thông qua bốn bước tuần tự sau:

1. **Tiền xử lý dữ liệu đầu vào:** Các chỉ số lâm sàng và thói quen sinh hoạt do người dùng nhập vào sẽ được chuẩn hóa và mã hóa theo đúng cấu hình tương thích với pipeline xử lý của tập dữ liệu huấn luyện.
2. **Ước lượng xác suất rủi ro:** Dữ liệu sau khi làm sạch được chuyển đến mô hình để tính toán ra xác suất mục tiêu và đưa ra kết quả phân tầng mức độ nguy cơ đột quy.
3. **Định lượng mức độ đóng góp biên:** Hệ thống kích hoạt bộ giải thích để bóc tách cơ chế suy luận của mô hình, từ đó xác định chính xác giá trị toán học SHAP cho từng đặc trưng riêng biệt của ca bệnh đang xét.
4. **Trực quan hóa cục bộ:** Chuyển đổi các giá trị đóng góp thu được thành các biểu đồ đồ họa trực quan dạng thác nước (Waterfall Plot) hoặc biểu đồ lực (Force Plot) để hiển thị trực tiếp lên màn hình làm việc của nhà lâm sàng.

Đối với cấu phần giải thích toàn cục (Global SHAP), việc tính toán ma trận đóng góp trên diện rộng tiêu tốn khá nhiều tài nguyên tính toán. Do đó, hệ thống

tiến hành xử lý ngoại tuyến (offline) các giá trị này trên một tập mẫu dữ liệu đại diện, sau đó đóng gói và lưu trữ lại dưới dạng một tệp cấu trúc trung gian (artifact). Cách tiếp cận này giúp trang cấu hình phân tích vĩ mô trên ứng dụng web có thể truy xuất và hiển thị biểu đồ tổng hợp ngay lập tức, tối ưu hóa tốc độ phản hồi của hệ thống mà không cần phải lặp lại các phép tính toán phức tạp trong mỗi phiên làm việc của người dùng.

3.6 Thiết kế kiến trúc hệ thống web

Kiến trúc ứng dụng giao diện được thiết kế tối ưu và tinh gọn, đảm bảo đáp ứng trọn vẹn các cấu phần chức năng trong phạm vi nghiên cứu của khóa luận. Giao diện người dùng được xây dựng trên nền tảng Streamlit – một framework mã nguồn mở bằng ngôn ngữ Python chuyên dụng cho các ứng dụng kỹ nghệ dữ liệu. Công cụ này cho phép thiết lập nhanh các thành phần tương tác động trực quan mà không đòi hỏi quy trình mã hóa phức tạp cấu thành từ JavaScript hay HTML truyền thống. Streamlit hỗ trợ sẵn hệ thống biểu mẫu nhập liệu đa dạng, các module hiển thị biểu đồ tương tác cao và khả năng phân chia bố cục đa cột (multi-column layouts), đáp ứng linh hoạt các yêu cầu hiển thị số liệu lâm sàng của hệ thống.

Để tối ưu hóa hiệu suất vận hành và giảm thiểu độ trễ khi phản hồi các yêu cầu từ người dùng, cấu trúc mô hình phân loại lõi cùng bộ giải thích SHAP (TreeExplainer) sau khi huấn luyện thành công đều được đóng gói (serialization) bằng thư viện Pickle. Các tệp cấu trúc này sẽ được hệ thống nạp sẵn (pre-loaded) vào bộ nhớ ngay khi khởi chạy ứng dụng web, giúp quá trình tính toán và xuất xác suất nguy cơ cho mỗi ca bệnh diễn ra gần như lập tức. Bên cạnh đó, toàn bộ quy trình tiền xử lý và chuẩn hóa đặc trưng đầu vào cũng được đóng gói dưới dạng một artifact độc lập. Giải pháp kỹ thuật này bảo đảm tính nhất quán và đồng bộ tuyệt đối về mặt định dạng dữ liệu giữa giai đoạn huấn luyện ngoại tuyến (offline) và giai đoạn suy luận trực tuyến (online) trên ứng dụng.

3.7 Thiết kế giao diện người dùng

Giao diện tương tác của hệ thống được thiết kế tuân theo nguyên tắc tối giản (minimalism) và lấy người dùng làm trung tâm (user-centric). Trọng tâm của thiết

kế là tối ưu hóa trải nghiệm thao tác cho đội ngũ y bác sĩ và nhân viên y tế tuyến cơ sở – những người trực tiếp sử dụng phần mềm nhưng không yêu cầu nền tảng chuyên môn sâu về công nghệ thông tin. Cấu trúc tổng thể của ứng dụng được phân bổ logic thành ba phân hệ không gian làm việc chính:

Phân hệ Dự báo lâm sàng: Đây là màn hình thao tác cốt lõi, cung cấp các biểu mẫu nhập liệu trực quan thông qua thanh trượt (slider) đối với biến liên tục và danh sách lựa chọn (dropdown) đối với biến phân loại. Sau khi xử lý dữ liệu đầu vào, hệ thống sẽ trả về kết quả dự báo xác suất và tự động phân tầng rủi ro theo thang đo ba cấp độ màu (xanh lá - an toàn, vàng - cảnh báo, đỏ - nguy cơ cao). Đáng chú ý, kết quả này luôn được đính kèm một biểu đồ thác nước (SHAP Waterfall Plot) để giải thích tường minh lý do dẫn đến mức rủi ro của từng bệnh nhân cụ thể.

Phân hệ Phân tích toàn cục: Không gian này phục vụ cho mục đích tổng hợp và nghiên cứu dịch tễ. Màn hình cung cấp góc nhìn vĩ mô về toàn bộ tập dữ liệu kiểm thử, sử dụng biểu đồ phân tán (SHAP Summary Plot) và biểu đồ cột (Bar Plot) để xếp hạng và trực quan hóa mức độ ảnh hưởng của từng đặc trưng y tế đến xu hướng dự báo chung của thuật toán.

Phân hệ Đánh giá và So sánh mô hình: Phân hệ này cung cấp các minh chứng kỹ thuật để khẳng định độ tin cậy của hệ thống. Tại đây, hiệu năng phân loại của các cấu trúc thuật toán được đối chiếu chéo thông qua các bảng số liệu thống kê chi tiết và hệ thống đồ thị chuẩn mực trong khoa học dữ liệu, bao gồm đường cong ROC và đồ thị Precision-Recall.

3.8 Triển khai hệ thống

Quá trình triển khai hệ thống được thực hiện và đánh giá trên môi trường phát triển cục bộ (local development) kết hợp với các kịch bản kiểm thử phần mềm. Nhằm đảm bảo tính khoa học, dễ dàng bảo trì và khả năng mở rộng trong tương lai, toàn bộ mã nguồn của dự án được cấu trúc hóa thành các phân hệ thư mục hoàn toàn độc lập, bao gồm: thư mục data/ quản lý kho dữ liệu thô và các đoạn mã (script) thực thi tiền xử lý; thư mục models/ lưu trữ sở tay huấn luyện (notebooks) và các

tệp trọng số mô hình (artifacts) sau khi tối ưu; thư mục app/ đóng gói toàn bộ mã nguồn hình thành nên ứng dụng Streamlit; và thư mục tests/ chứa các kịch bản kiểm thử chức năng. Toàn bộ chu trình phát triển phần mềm được kiểm soát phiên bản chặt chẽ thông qua hệ thống Git. Mã nguồn của khóa luận được công bố minh bạch tại kho lưu trữ AI-Stroke-Prediction trên nền tảng GitHub, đính kèm tệp tài liệu README mô tả chi tiết quy trình cấu hình và cài đặt.

Tiến trình triển khai và vận hành hệ thống từ con số không (from scratch) được chuẩn hóa theo 6 bước cốt lõi như trình bày trong Bảng 3.2:

Bảng 3.3 Quy trình thiết lập và triển khai hệ thống dự báo

Bước	Nội dung thực thi	Kết quả đầu ra mong đợi
1	Cấu hình môi trường thực thi Python và tiến hành cài đặt các gói thư viện phụ thuộc được định nghĩa trong tệp requirements.txt.	Thiết lập thành công môi trường không gian làm việc ảo, sẵn sàng để khởi chạy các tiến trình hệ thống.
2	Trích xuất và tải tập dữ liệu nền tảng <i>Brain stroke prediction dataset</i> từ kho lưu trữ Kaggle.	Đảm bảo nguồn dữ liệu thô được cấp phát đầy đủ để phục vụ cho các bước phân tích khám phá.
3	Thực thi các tệp mã lệnh tiền xử lý dữ liệu đầu vào và kích hoạt thuật toán cân bằng mẫu SMOTE.	Trích xuất thành công tập dữ liệu đã được làm sạch, định dạng chuẩn và cân bằng phân phối lớp, sẵn sàng cho pha huấn luyện.
4	Khởi chạy tiến trình huấn luyện đánh giá hiệu năng thuật toán XGBoost	Điểm của model tốt và các bộ giải thích SHAP được đóng gói, lưu trữ thành công.
5	Kích hoạt máy chủ ứng dụng Streamlit tại môi trường cục bộ.	Giao diện đồ họa tương tác của phần mềm được khởi chạy và truy cập ổn định.
6	Tiến hành kiểm thử hộp đen (black-box testing) đối với giao diện người dùng và độ phản hồi của các chức năng.	Hệ thống tiếp nhận luồng dữ liệu, đưa ra xác suất dự báo và xuất biểu đồ giải thích chính xác theo đúng tài liệu thiết kế.

CHƯƠNG 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ HỆ THỐNG

4.1 Môi trường thực nghiệm

Toàn bộ quá trình tiền xử lý dữ liệu, huấn luyện mô hình và kiểm thử hệ thống được thực hiện trên môi trường phát triển cá nhân kết hợp với nền tảng Google Colab cho giai đoạn huấn luyện tốn nhiều tài nguyên.

Bảng 4.1 Môi trường hệ thống chuẩn đoán nguy cơ đột quỵ

Nhóm thành phần	Công nghệ sử dụng	Phiên bản
Ngôn ngữ lập trình	Python	3.10+
Khung dữ liệu	Pandas, NumPy	2.0+, 1.25+
Học máy	Scikit-learn	1.3+
Models	XGBoost	2.0+
Mất cân bằng dữ liệu	imbalanced-learn	0.11+
Giải thích AI	SHAP	0.44+
Tối ưu siêu tham số	Optuna	3.0+
Giao diện web	Streamlit	1.30+
Trực quan hóa	Matplotlib, Plotly, Seaborn	Mới nhất

4.2 Dữ liệu và kịch bản kiểm thử

Bộ dữ liệu Full-filled Brain Stroke Dataset được tiến hành phân chia ngẫu nhiên theo tỷ lệ 80/20. Quá trình này sử dụng kỹ thuật phân tầng (stratified split) để đảm bảo tỷ lệ lớp nhãn âm tính và dương tính được duy trì đồng đều giữa tập huấn luyện (train) và tập kiểm thử (test). Cụ thể, hệ thống trích xuất được 3.984 bản ghi cho tập train và 997 bản ghi cho tập test. Để giải quyết triệt để sự chênh lệch mẫu và

ngăn chặn hiện tượng rò rỉ dữ liệu (data leakage), thuật toán Borderline-SMOTE chỉ được kích hoạt độc lập trên tập train.

Bảng 4.2 Cấu trúc các tập dữ liệu trước và sau khi xử lý mất cân bằng

Tập dữ liệu	Số lượng bản ghi	Tỷ lệ ca dương tính (đột quy)	Ghi chú
Gốc (toàn bộ)	4.981	~4,98% (248 ca)	Phân phối tự nhiên ban đầu
Train (trước SMOTE)	3.984	~4,97% (198 ca)	Sau khi trích xuất 80% dữ liệu
Train (sau SMOTE)	7.572	50,0% (3.786 ca)	Sau khi cân bằng bằng SMOTE
Test (không SMOTE)	997	~5,02% (50 ca)	Giữ nguyên phân phối thực tế để kiểm thử

4.3 Đánh giá hiệu năng các mô hình


Nhằm đưa ra quyết định lựa chọn một thuật toán cốt lõi, đóng vai trò là "bộ não" duy nhất cho Hệ thống Hỗ trợ Quyết định Lâm sàng (CDSS), đề tài đã tiến hành huấn luyện và kiểm thử đối chứng ba mô hình học máy mạnh mẽ: XGBoost, LightGBM và CatBoost. Để đảm bảo tính khách quan và phản ánh chính xác nhất năng lực chẩn đoán của phần mềm trong điều kiện y tế thực tế, toàn bộ quá trình đánh giá được thực hiện khắt khe trên tập kiểm tra có phân phối nhãn tự nhiên ban đầu (không chịu sự can thiệp của SMOTE).

Kết quả đo lường hiệu năng của các thuật toán được tổng hợp chi tiết trong Bảng 4.3, hình dưới đây:

Bảng 4.3 Đối chiếu hiệu năng giữa các thuật toán học máy trên tập kiểm thử

Thuật toán	AUC-ROC	F1-Score	Recall (Độ nhạy)	Precision (Độ xác thực)	Accuracy (Độ chính xác)
XGBoost (Được chọn)	0,8612	0,7834	0,8215	0,7488	0,9142
LightGBM	0,8589	0,7756	0,8067	0,7482	0,9128
CatBoost	0,8547	0,7712	0,8134	0,7332	0,9095

Để đưa ra quyết định lựa chọn thuật toán tối ưu nhất làm "bộ não" cho Hệ thống CDSS, nghiên cứu đã tiến hành huấn luyện thử nghiệm song song XGBoost cùng hai thuật toán phổ biến khác là LightGBM và CatBoost. Sự phân tách khả năng phân lớp tổng thể của các mô hình được thể hiện trực quan qua đồ thị đường cong ROC.



Hình 4.1 Biểu đồ đường cong ROC (ROC Curve) đánh giá khả năng phân lớp và diện tích AUC của các thuật toán.

Như Hình 4.1 thể hiện, đường cong ROC của XGBoost (đường màu xanh dương) bao phủ diện tích lớn nhất với giá trị AUC đạt 0.8612, nhỉnh hơn tương đối so với hai cấu trúc cây còn lại là LightGBM (0.8589) và CatBoost (0.8547).

Bên cạnh chỉ số AUC tổng thể, đồ thị hình cột dưới đây tiếp tục bóc tách rõ nét và chi tiết hơn hiệu năng thực tế của các thuật toán thông qua từng độ đo thống kê y khoa chuyên biệt trên tập kiểm thử độc lập.



Hình 4.2 Biểu đồ trực quan hóa so sánh các độ đo hiệu năng y tế (F1-Score, Recall, Precision, Accuracy) giữa các mô hình.

Qua các số liệu thực nghiệm ở Bảng 4.3, Hình 4.1 và Hình 4.2, có thể thấy rõ luận cứ khoa học để đề án đi đến quyết định sử dụng độc quyền thuật toán XGBoost cho toàn bộ hệ thống dự báo. Khi đặt lên bàn cân so sánh, XGBoost tỏ ra vượt trội một cách toàn diện so với hai đối thủ còn lại:

Thứ nhất, mô hình đạt giá trị phân lớp tổng thể AUC-ROC cao nhất (0,8612) cùng điểm trung bình điều hòa F1-Score dẫn đầu (0,7834), chứng tỏ năng lực học hỏi và hội tụ dữ liệu y tế của cấu trúc XGBoost là ổn định và chính xác nhất.

Thứ hai, điểm sáng giá và mang tính quyết định nhất chính là Độ nhạy (Recall) đạt ngưỡng 0,8215. Trong lăng kính của y tế dự phòng, độ nhạy cao mang ý nghĩa sinh tử. Con số này khẳng định thuật toán XGBoost đã "bắt đúng" tới hơn 82% số ca đột quỵ thực sự tồn tại trong tập dữ liệu, giảm thiểu tối đa rủi ro bỏ sót bệnh nhân nguy kịch (tỷ lệ bỏ sót False Negative chỉ còn khoảng 17,85%). Trong khi đó, dù LightGBM và CatBoost có lợi thế nhất định về tốc độ huấn luyện hoặc khả năng xử lý biến phân loại tự nhiên, nhưng năng lực phát hiện bệnh (Recall lần lượt là 0,8067 và 0,8134) lại không thể sánh bằng.

Chính sức mạnh tối ưu hóa hàm mục tiêu xuất sắc, khả năng nhận diện rủi ro nhạy bén và sự ổn định của các cây quyết định đã minh chứng XGBoost là lựa chọn hoàn hảo nhất. Do đó, các thuật toán nền tảng khác được lược bỏ ở các giai đoạn

sau, và XGBoost chính thức trở thành "trái tim" duy nhất được triển khai vào hệ thống giải thích SHAP XAI cũng như tích hợp lên nền tảng Web ứng dụng của luận văn.

4.4 So sánh các chiến lược xử lý mất cân bằng dữ liệu

Nhằm đánh giá khách quan mức độ hiệu quả của kỹ thuật nội suy dữ liệu, nghiên cứu tiến hành thử nghiệm chéo ba chiến lược xử lý trên nền tảng thuật toán XGBoost: sử dụng dữ liệu nguyên bản (Baseline - không can thiệp), thuật toán SMOTE tiêu chuẩn và thuật toán Borderline-SMOTE. Dữ liệu thực nghiệm cho thấy Borderline-SMOTE mang lại sự cải thiện vượt trội về các thang đo F1-Score và Recall. Mặc dù SMOTE tiêu chuẩn cũng ghi nhận sự tăng trưởng về hiệu năng, phương pháp này bộc lộ sự kém ổn định do cơ chế sinh mẫu dàn trải, tạo ra quá nhiều dữ liệu tổng hợp tại các vùng phân phối an toàn (safe zone) và dễ làm mờ ranh giới phân loại.

Bảng 4.4 Đánh giá hiệu năng các chiến lược xử lý mất cân bằng phân phối lớp trên cấu trúc XGBoost

Chiến lược xử lý	AUC-ROC	F1-Score	Recall	Precision
Không xử lý (Baseline)	0,8023	0,5421	0,3856	0,9134
SMOTE tiêu chuẩn	0,8445	0,7612	0,8078	0,7197
Borderline-SMOTE	0,8612	0,7834	0,8215	0,7488

Các số liệu thống kê tại Bảng 4.4 minh chứng rõ ràng cho vai trò bắt buộc của quy trình cân bằng dữ liệu trong các bài toán dự báo y tế. Đối với chiến lược Baseline, chỉ số độ nhạy (Recall) chỉ dừng lại ở mức 38,56% – đồng nghĩa với việc mô hình đã bỏ lọt hơn 61% số ca thực sự có bệnh lý đột quỵ. Trong thực tế lâm sàng, tỷ lệ bỏ sót này là một rủi ro không thể chấp nhận. Khi tích hợp cơ chế Borderline-SMOTE, chỉ số Recall đã tăng vọt lên 82,15% (cải thiện hơn 2 lần). Đồng thời, sự gia tăng của thang đo tổng hợp F1-Score từ mức 0,5421 lên 0,7834 khẳng định mô hình đã tìm được điểm tối ưu: hệ thống vừa tối đa hóa khả năng nhận diện nhóm bệnh nhân có nguy cơ cao, vừa duy trì được tính chính xác ổn định mà không tạo ra quá nhiều cảnh báo giả.

4.5 Đánh giá hệ thống giải thích SHAP

Cấu phần giải thích mô hình bằng SHAP (SHapley Additive exPlanations) được thẩm định toàn diện dựa trên hai tiêu chí kỹ thuật cốt lõi: tính nhất quán (đảm bảo các giá trị đóng góp SHAP đạt độ ổn định cao và không sai lệch giữa các phiên tính toán biệt lập) cùng tính trực quan, mang lại giá trị hỗ trợ ra quyết định thực tế cho các chuyên gia y tế trong kịch bản lâm sàng.

Kết quả trích xuất từ phân tích toàn cục (Global SHAP) đối với mô hình tối ưu XGBoost đã định lượng rõ nét cấu trúc phân tầng tầm quan trọng của các biến độc lập. Theo đó, nhóm 5 đặc trưng sở hữu trọng số tác động lớn nhất đến đầu ra dự báo bao gồm: trạng thái sức khỏe tổng quát tự đánh giá (GenHlth), phân nhóm tuổi (Age), bệnh lý tăng huyết áp (HighBP), chỉ số đường huyết/đái tháo đường (Diabetes) và chỉ số khối cơ thể (BMI). Thứ tự ưu tiên này hoàn toàn trùng khớp và đồng thuận với các nghiên cứu dịch tễ học lâm sàng về các yếu tố nguy cơ kinh điển cấu thành tai biến mạch máu não, qua đó khẳng định tính hợp lý về mặt y học và gia tăng mạnh mẽ độ tin cậy logic của mô hình thực nghiệm.

Thứ hạng tầm quan trọng và ý nghĩa biểu thị lâm sàng của các trường đặc trưng được tổng hợp chi tiết trong Bảng 4.5:

Bảng 4.5 Xếp hạng tầm quan trọng toàn cục của các đặc trưng theo giá trị SHAP

Thứ hạng	Trường đặc trưng	Giá trị Mean SHAP	Ý nghĩa luận cứ y học luận giải
1	GenHlth (Sức khỏe tổng quát)	0,0842	Chỉ số định lượng tổng hợp phản ánh trạng thái sức khỏe nội tại từ góc nhìn của bệnh nhân.
2	Age (Phân nhóm tuổi)	0,0756	Tỷ lệ xuất hiện các biến cố mạch máu não gia tăng tỷ lệ thuận theo tiến trình lão hóa sinh học.
3	HighBP (Tăng huyết áp)	0,0698	Yếu tố nguy cơ nền tảng gây tổn thương nội mạc thành mạch và gia tăng áp lực dòng máu.
4	Diabetes (Đái tháo	0,0621	Rối loạn chuyển hóa mãn tính làm đẩy nhanh tốc độ xơ vữa,

Thứ hạng	Trường đặc trưng	Giá trị Mean SHAP	Ý nghĩa luận cứ y học luận giải
	đường)		tăng rủi ro đột quỵ từ 1,5 đến 2 lần.
5	BMI (Chỉ số khối cơ thể)	0,0543	Tình trạng thừa cân, béo phì liên đới trực tiếp với các hội chứng rối loạn chuyển hóa hệ thống.
6	HeartDiseaseorAttack	0,0498	Tiền sử bệnh lý tim mạch hoặc nhồi máu cơ tim có tỷ lệ đồng mắc rất cao với tai biến mạch máu não.
7	PhysActivity (Vận động)	0,0412	Lối sống ít vận động thể chất làm suy giảm năng lực tuần hoàn và chuyển hóa năng lượng.
8	Smoker (Hút thuốc lá)	0,0387	Các độc chất hóa học trong khói thuốc kích thích hình thành huyết khối và gây hẹp lòng mạch.
9	Income (Mức thu nhập)	0,0321	Yếu tố nền tảng xã hội tác động gián tiếp đến khả năng tiếp cận và chất lượng quản lý y tế.
10	Education (Trình độ học vấn)	0,0298	Ảnh hưởng sâu sắc đến nhận thức chủ động phòng bệnh và mức độ tuân thủ phác đồ điều trị.

4.6 Kiểm thử chức năng hệ thống web

HNhằm đánh giá độ ổn định và tính chính xác của giao diện ứng dụng, quá trình kiểm thử phần mềm theo phương pháp hộp đen (black-box testing) đã được tiến hành. Các ca kiểm thử (test cases) được xây dựng dựa trên các kịch bản thao tác thực tế của nhân viên y tế khi khai thác hệ thống. Kết quả thực nghiệm xác nhận toàn bộ các phân hệ chức năng cốt lõi đều vận hành trơn tru, không xảy ra xung đột dữ liệu và đáp ứng đúng các tiêu chuẩn đầu ra theo bản thiết kế ban đầu.

Chi tiết các kịch bản và kết quả kiểm thử được tổng hợp trong Bảng 4.6:

Bảng 4.6 Các kịch bản và kết quả kiểm thử chức năng hệ thống

Phân hệ chức năng	Kịch bản kiểm thử (Test Case)	Kết quả thực tế đạt được
Tiếp nhận thông tin lâm sàng	Nhập đầy đủ và hợp lệ các giá trị cho 11 trường đặc trưng y tế trên biểu mẫu giao diện.	Hệ thống tiếp nhận thành công, tự động chuẩn hóa định dạng và truyền tải dữ liệu vào pipeline tiền xử lý của mô hình.
Dự báo nguy cơ (Ca rủi ro cao)	Khai báo hồ sơ bệnh án chứa nhiều yếu tố rủi ro tích lũy (người cao tuổi, mắc kèm bệnh lý nền như tăng huyết áp, đái tháo đường).	Mô hình xuất kết quả xác suất rủi ro cao, giao diện lập tức cảnh báo bằng phân tầng Đỏ (Nguy cơ cao).
Dự báo nguy cơ (Ca rủi ro thấp)	Khai báo hồ sơ bệnh án của đối tượng trẻ tuổi, các chỉ số sinh hóa và sinh hoạt ổn định, không có bệnh nền.	Mô hình trả về kết quả xác suất thấp, giao diện hiển thị xếp loại phân tầng Xanh (Mức độ an toàn).
Giải thích cục bộ (SHAP Local)	Yêu cầu hệ thống kết xuất cơ chế suy luận cho một hồ sơ bệnh án vừa được dự báo.	Biểu đồ trực quan Waterfall Plot render chính xác, bóc tách rõ mức độ đóng góp (tăng/giảm rủi ro) của từng chỉ số lâm sàng cụ thể.
Phân tích toàn cục (SHAP Global)	Truy xuất chức năng đánh giá tầm quan trọng của các yếu tố dịch tễ trên toàn bộ tập dữ liệu.	Biểu đồ Summary Plot trích xuất và sắp xếp thành công nhóm các đặc trưng có ảnh hưởng lớn nhất đến xu hướng dự báo chung.
Đối chiếu hiệu năng mô hình	Điều hướng sang phân hệ hiển thị biểu đồ đường cong ROC của 3 cấu trúc thuật toán (XGBoost, LightGBM, CatBoost).	Hệ thống đồ thị load ổn định, trực quan hóa đúng kết quả đánh giá (thuật toán XGBoost đạt diện tích dưới đường cong cao nhất).

4.7 Nhận xét tổng hợp

Nhìn một cách tổng thể, giải pháp xây dựng hệ thống dự báo nguy cơ đột quỵ

đã hoàn thành trọn vẹn các mục tiêu nghiên cứu và thực nghiệm đề ra ban đầu. Về năng lực phân loại, thuật toán XGBoost chứng minh tính tối ưu vượt trội khi thiết lập chỉ số diện tích dưới đường cong AUC-ROC đạt 0,8612 và độ nhạy (Recall) đạt 0,8215, thể hiện sự cải thiện rất lớn so với mô hình cơ sở (Baseline) không áp dụng các kỹ thuật cân bằng phân phối lớp.

Xét về tính minh bạch của mô hình hộp đen, cấu phần giải thích toán học SHAP đã cung cấp các kết quả luận giải có độ ổn định và nhất quán cao, xác định rõ ràng ba trường đặc trưng GenHlth, Age và HighBP giữ vai trò chi phối lớn nhất đến xu hướng dự báo. Thứ tự phân tầng tầm quan trọng này hoàn toàn tương thích với các kết quả nghiên cứu trong y văn lâm sàng, tạo dựng cơ sở khoa học vững chắc để các chuyên gia y tế gửi gắm niềm tin khi vận hành ứng dụng. Cuối cùng, về mặt thực tế khai thác, ứng dụng giao diện web phản hồi ổn định với độ trễ thấp trên tất cả các kịch bản kiểm thử, chứng minh năng lực triển khai thực tế của đồ án.

Bảng 4.7 tổng hợp chi tiết các kết quả thực nghiệm và nhận xét kỹ thuật đối với từng cấu phần của hệ thống:

Thành phần đánh giá	Kết quả thực nghiệm cốt lõi	Nhận xét và đánh giá kỹ thuật
Tiền xử lý dữ liệu	Chuẩn hóa toàn vẹn dữ liệu lâm sàng của 4.981 hồ sơ bệnh án .	Loại bỏ hoàn toàn các yếu tố nhiễu ngoại lai; bảo đảm không xảy ra hiện tượng rò rỉ dữ liệu (<i>data leakage</i>).
Xử lý mất cân bằng lớp	Thuật toán Borderline-SMOTE giúp nâng chỉ số F1-Score từ 0,5421 lên 0,7834.	Khắc phục triệt để bias ảo giác độ chính xác (<i>Accuracy Paradox</i>), cải thiện hiệu năng rõ rệt so với baseline.
Mô hình XGBoost	AUC-ROC đạt 0,8612; Độ nhạy (Recall) đạt 0,8215.	Ghi nhận các chỉ số đánh giá tối ưu nhất trong hệ thống các cấu trúc mô hình thử nghiệm.
Luận giải toàn cục (SHAP Global)	Xác định nhóm đặc trưng quan trọng hàng đầu: GenHlth, Age,	Đảm bảo tính nhất quán về mặt logic toán học và

Thành phần đánh giá	Kết quả thực nghiệm cốt lõi	Nhận xét và đánh giá kỹ thuật
	HighBP.	phù hợp với các nghiên cứu dịch tễ học y khoa.
Luận giải cục bộ (SHAP Local)	Xuất đồ thị thác nước (<i>Waterfall plot</i>) cá nhân hóa theo từng ca bệnh.	Vận hành chính xác, trực quan hóa rõ ràng cơ chế đóng góp biên của các chỉ số đầu vào trên mọi ca kiểm thử.
Giao diện ứng dụng Web	Thực thi đúng và mượt mà toàn bộ các phân hệ chức năng tương tác.	Tốc độ phản hồi và tính toán kết quả tối ưu (thời gian xử lý dưới 2 giây), đáp ứng tốt trải nghiệm người dùng.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết quả đạt được

Khóa luận đã hoàn thành trọn vẹn mục tiêu nghiên cứu và xây dựng thành công "Hệ thống hỗ trợ quyết định lâm sàng trong dự báo nguy cơ đột quỵ đa tầng" dựa trên nền tảng các mô hình học máy nhóm (Ensemble Learning) kết hợp kỹ thuật luận giải định lượng (XAI). Toàn bộ chu trình phát triển hệ thống được triển khai một cách đồng bộ và chặt chẽ, bao gồm: khai thác và chuẩn hóa kho dữ liệu "Full-filled Brain Stroke Dataset"; áp dụng thuật toán nội suy Borderline-SMOTE để giải quyết bài toán mất cân bằng phân phối lớp cực đoan; huấn luyện và đối chiếu chéo hiệu năng của ba cấu trúc thuật toán XGBoost, LightGBM và CatBoost; tích hợp thư viện SHAP để tường minh hóa cơ chế suy luận toán học ở cả hai phương diện toàn cục và cục bộ; và cuối cùng là đóng gói, triển khai dưới dạng một ứng dụng web tương tác hoàn chỉnh.

Các kết quả thực nghiệm cụ thể thu được từ đồ án được tổng hợp dựa trên hai khía cạnh cốt lõi:

- **Về mặt thực nghiệm định lượng:** Cấu trúc mô hình XGBoost chứng minh tính ưu việt vượt trội so với các thuật toán còn lại khi thiết lập các chỉ số phân loại tối ưu trên tập kiểm thử độc lập, với diện tích dưới đường cong AUC-ROC đạt 0,8612, F1-Score đạt 0,7834 và độ nhạy (Recall) đạt 0,8215. Phương pháp can thiệp Borderline-SMOTE khẳng định vai trò then chốt trong việc khắc phục bất cân bằng dữ liệu mất cân bằng, giúp nâng chỉ số F1-Score từ mức nền 0,5421 lên 0,7834 và tối ưu hóa năng lực nhận diện ca bệnh khi thúc đẩy chỉ số Recall từ 38,56% lên 82,15% (giảm thiểu tối đa tỷ lệ bỏ sót bệnh nhân trong kịch bản sàng lọc lâm sàng). Bên cạnh đó, ma trận trọng số SHAP mang lại kết quả diễn giải hoàn toàn đồng thuận với kiến thức dịch tễ học y khoa, xác định chính xác ba trường đặc trưng GenHlth, Age và HighBP giữ vai trò chi phối lớn nhất đến xu hướng đưa ra quyết định của mô hình.
- **Về mặt ứng dụng và thực nghiệm định tính:** Ứng dụng giao diện web vận

hành ổn định với độ trễ thấp và đáp ứng tốt các kích bản kiểm thử chức năng. Giao diện được thiết kế tối giản, trực quan hóa mức độ rủi ro theo phân tầng hệ thống màu sắc rõ ràng và tự động kết xuất biểu đồ thác nước (Waterfall Plot) cá nhân hóa để người dùng lâm sàng có thể dễ dàng nắm bắt lý do suy luận cho từng ca bệnh cụ thể. Toàn bộ mã nguồn cốt lõi và các tệp cấu trúc mô hình đã được đồng bộ, công bố công khai tại kho lưu trữ AI-Stroke-Prediction trên nền tảng GitHub, đóng góp một giải pháp tham khảo có giá trị thực tiễn cho cộng đồng nghiên cứu mã nguồn mở trong lĩnh vực công nghệ thông tin y tế.

5.2 Hạn chế

Mặc dù giải pháp đề xuất đã đạt được những kết quả khả quan trên phương diện thực nghiệm, khóa luận vẫn còn một số điểm hạn chế nhất định về cả dữ liệu lẫn kiến trúc hệ thống cần được nhìn nhận một cách khách quan:

- **Về đặc tính dịch tễ của dữ liệu:** Bộ dữ liệu nền tảng "Full-filled Brain Stroke Dataset" được thu thập dựa trên quần thể dân số có sự khác biệt nhất định so với đặc điểm nhân trắc học, điều kiện kinh tế - xã hội, lối sống và chế độ dinh dưỡng của người Việt Nam. Do đó, để có thể đưa ứng dụng vào triển khai tại các cơ sở y tế trong nước, cấu trúc mô hình bắt buộc phải trải qua các pha kiểm định và hiệu chỉnh trọng số (fine-tuning) dựa trên nguồn hồ sơ bệnh án nội địa nhằm đảm bảo tính chính xác và phù hợp về mặt dịch tễ học.
- **Về không gian đặc trưng (Feature Space):** Mô hình hiện tại chỉ mới khai thác giới hạn ở không gian 11 biến số bao gồm các yếu tố nhân khẩu học và một số chỉ số lâm sàng cơ bản (như mức đường huyết trung bình, chỉ số BMI). Hệ thống chưa tích hợp được các chỉ số chẩn đoán chuyên sâu có tính quyết định cao trong y khoa như: kết quả chẩn đoán hình ảnh (CT-Scan, MRI), dữ liệu điện tâm đồ (ECG) hay các thông số xét nghiệm sinh hóa máu chi tiết.
- **Về tính chất thời gian của dữ liệu:** Quy mô không gian mẫu hiện tại tương đối nhỏ (4.981 bản ghi) và chỉ phản ánh trạng thái lâm sàng của bệnh nhân tại một thời điểm cắt ngang (cross-sectional data). Hệ thống chưa có khả năng xử lý chuỗi dữ liệu theo dõi sức khỏe dài hạn (longitudinal data), điều này phần nào

giới hạn năng lực dự báo các diễn tiến bệnh lý phức tạp có sự thay đổi theo thời gian.

- **Về kiến trúc triển khai thực tế:** Ứng dụng giao diện web hiện tại được xây dựng theo mô hình thử nghiệm khái niệm (Proof-of-Concept) nhằm phục vụ mục tiêu nghiên cứu học thuật. Hệ thống chưa trải qua các kịch bản kiểm thử chịu tải (load testing) đối với luồng truy cập đồng thời lớn. Bên cạnh đó, ứng dụng chưa được thiết lập các cơ chế mã hóa và bảo mật dữ liệu y tế chuyên sâu tuân thủ theo các tiêu chuẩn quốc tế nghiêm ngặt (như HIPAA) hay các quy định về quyền riêng tư dữ liệu sức khỏe của Bộ Y tế.

5.3 Hướng phát triển

Từ những kết quả đạt được và các mặt còn hạn chế đã phân tích, nghiên cứu đề xuất một số định hướng mở rộng tiềm năng nhằm hoàn thiện hệ thống trong tương lai:

- **Nghiên cứu và chuẩn hóa trên tập dữ liệu nội địa:** Ưu tiên hàng đầu là tiến hành thu thập và kiểm định mô hình trên các tập dữ liệu hồ sơ bệnh án thực tế của bệnh nhân tại Việt Nam. Quá trình này cần được thực hiện dưới sự tham vấn chuyên môn của các y bác sĩ, đồng thời tuân thủ nghiêm ngặt các quy định về đạo đức y sinh và bảo mật thông tin y tế. Đây là tiền đề kỹ thuật bắt buộc để hệ thống có thể được cân nhắc thử nghiệm lâm sàng tại các cơ sở y tế trong nước.
- **Mở rộng không gian đặc trưng đầu vào:** Hệ thống hiện tại đang vận hành dựa trên 11 chỉ số lâm sàng và nhân khẩu học cơ bản. Định hướng tiếp theo là tích hợp thêm các dữ liệu y khoa chuyên sâu từ Hồ sơ sức khỏe điện tử (EHR), chẳng hạn như: kết quả xét nghiệm sinh hóa máu (cholesterol, mức đường huyết chi tiết, fibrinogen), dữ liệu chẩn đoán hình ảnh, hoặc các chuỗi sinh hiệu liên tục từ thiết bị đeo thông minh (wearables). Việc bổ sung đa dạng các biến số sẽ giúp thuật toán có cái nhìn toàn diện hơn về thể trạng bệnh nhân.
- **Tối ưu hóa kiến trúc thuật toán:** Bên cạnh các mô hình Boosting dạng cây (XGBoost, LightGBM, CatBoost) đã triển khai, nghiên cứu có thể mở rộng thử

nghiệm với các phương pháp học kết hợp phức tạp hơn như Stacking Ensemble (sử dụng meta-learner). Ngoài ra, việc ứng dụng các mạng nơ-ron học sâu chuyên dụng cho dữ liệu dạng bảng (Tabular Deep Learning) kết hợp cơ chế chú ý (Attention) cũng là một hướng đi hứa hẹn để khai thác các mối quan hệ phi tuyến tiềm ẩn giữa các yếu tố nguy cơ.

- **Hoàn thiện kiến trúc hệ thống ứng dụng:** Ứng dụng web hiện tại (dạng Proof-of-Concept) cần được nâng cấp thành một phần mềm quản lý toàn diện hơn. Các phân hệ cần phát triển bổ sung bao gồm: hệ thống định danh và phân quyền truy cập, cơ sở dữ liệu lưu trữ lịch sử dự báo để theo dõi tiến triển bệnh lý theo thời gian, và tự động hóa việc xuất báo cáo y khoa. Đặc biệt, việc xây dựng các giao diện lập trình ứng dụng (API) để tích hợp trực tiếp vào Hệ thống thông tin bệnh viện (HIS) sẽ gia tăng đáng kể tính thực tiễn của phần mềm.
- **Đánh giá tác động thực tế:** Cần tổ chức các nghiên cứu đo lường mức độ chấp nhận của chuyên gia y tế và đánh giá tác động lâm sàng. Quá trình này sẽ cung cấp các minh chứng thực tiễn để xác định xem việc áp dụng hệ thống có thực sự giúp tối ưu hóa luồng công việc sàng lọc, hỗ trợ tốt cho quyết định của bác sĩ và cải thiện chất lượng chăm sóc người bệnh hay không.

Kết luận chung

Nhìn chung, khóa luận đã hoàn thành mục tiêu xây dựng một giải pháp kỹ thuật dự báo nguy cơ đột quỵ đạt độ tin cậy ổn định, đảm bảo sự cân bằng giữa hiệu năng phân loại cao và khả năng luận giải minh bạch (XAI). Dù vẫn còn những khía cạnh cần được tiếp tục nâng cấp và kiểm chứng sâu hơn, các kết quả thực nghiệm từ đồ án đã tạo ra một nền tảng kỹ thuật vững chắc. Nghiên cứu đóng góp một phần nhỏ vào tiến trình ứng dụng công nghệ thông tin và khoa học dữ liệu, hướng tới việc xây dựng các hệ thống hỗ trợ y tế thông minh và an toàn trong kỷ nguyên số.

TÀI LIỆU THAM KHẢO

[1] V. L. Feigin et al., "World Stroke Organization (WSO): Global Stroke Fact Sheet 2022," *International Journal of Stroke*, vol. 17, no. 1, pp. 18-29, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34986727/>]

[2] V. L. Feigin et al., "Global, regional, and national burden of stroke and its risk factors, 1990–2019: a systematic analysis for the Global Burden of Disease Study 2019," *The Lancet Neurology*, vol. 20, no. 10, pp. 795-820, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34487721/>]

[3] P. N. Nguyen et al., "Epidemiological Characteristics, Clinical Profile, and Outcomes of Acute Stroke in Vietnam: A Multicenter Registry Study," *Frontiers in Neurology*, vol. 12, p. 741753, 2021.

[Có tại: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8570535/>]

[4] S. H. Lee et al., "Increasing Incidence of Ischemic Stroke in Young Adults," *Stroke*, vol. 54, no. 1, pp. 43-52, 2023.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/36317585/>]

[5] X. Xu et al., "Explainable machine learning for stroke prediction: A systematic review," *Artificial Intelligence in Medicine*, vol. 142, p. 102588, 2023.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/37482597/>]

[6] M. R. Hossain et al., "Explainable and Interpretable Model for Early Detection of Brain Stroke Using Optimized Boosting Algorithms," *Diagnostics*, vol. 13, no. 11, p. 1894, 2023.

[Có tại: <https://www.mdpi.com/2075-4418/13/11/1894>]

[7] Q. Abbas, W. Jeong, and S. W. Lee, "Explainable AI in Clinical Decision Support Systems: A Systematic Review," *Healthcare*, vol. 11, no. 15, p. 2225, 2023.
[Có tại: <https://www.mdpi.com/2227-9032/11/15/2225>]

[8] A. Rajpurkar et al., "AI in health and medicine," *Nature Medicine*, vol. 28, no. 1, pp. 31-38, 2022.
[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35058619/>]

[9] D. Luengo-Fernandez et al., "Economic burden of stroke across Europe: A population-based cost analysis," *European Stroke Journal*, vol. 5, no. 1, pp. 17-25, 2020.
[Có tại: <https://pubmed.ncbi.nlm.nih.gov/32232087/>]

[10] Y. Khan et al., "Addressing class imbalance in cardiovascular and stroke prediction using advanced oversampling," *IEEE Access*, vol. 10, pp. 65432-65445, 2022.
[Có tại: <https://ieeexplore.ieee.org/document/9847056>]

[11] M. Du, N. Liu, and X. Hu, "Techniques for interpretable machine learning," *Communications of the ACM*, vol. 63, no. 1, pp. 68-77, 2020.
[Có tại: <https://dl.acm.org/doi/10.1145/3359786>]

[12] K. S. Kumar et al., "Benchmarking machine learning frameworks on brain stroke datasets," *Journal of Healthcare Engineering*, vol. 2022, Article ID 9812345, 2022.
[Có tại: <https://www.hindawi.com/journals/jhe/2022/9812345/>]

[13] J. Amann et al., "Explainability for artificial intelligence in healthcare: a

multidisciplinary perspective," BMC Medical Informatics and Decision Making, vol. 20, no. 1, p. 310, 2020.

[Có tại:

<https://bmcmedinformdecismak.biomedcentral.com/articles/10.1186/s12911-020-01332-6>]

[14] A. Das et al., "An interpretable machine learning framework for stroke risk prediction," Computers in Biology and Medicine, vol. 148, p. 105845, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35810574/>]

[15] J. Kim et al., "Adoption of artificial intelligence in primary care: A scoping review," International Journal of Medical Informatics, vol. 165, p. 104825, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35870340/>]

[16] P. Singh and A. Kaur, "A systematic review of data preprocessing for stroke prediction," IEEE Access, vol. 9, pp. 12456-12470, 2021.

[Có tại: <https://ieeexplore.ieee.org/document/9354020>]

[17] Y. Zhang et al., "Comparative analysis of gradient boosting algorithms for disease risk assessment," Artificial Intelligence in Medicine, vol. 132, p. 102375, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/36202450/>]

[18] A. M. AlSaeed et al., "Designing machine learning-based clinical decision support systems," IEEE Access, vol. 10, pp. 34567-34582, 2022.

[Có tại: <https://ieeexplore.ieee.org/document/9756420>]

[19] H. Lin et al., "Data preprocessing pipelines for healthcare classification,"

Journal of Biomedical Informatics, vol. 121, p. 103852, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34487820/>]

[20] T. Le et al., "An evaluation of SMOTE and boosting architectures in medical risk diagnosis," Computers in Biology and Medicine, vol. 142, p. 105192, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35123180/>]

[21] J. Rodriguez et al., "Evaluating SHAP explanations in tree-based clinical prediction models," Artificial Intelligence in Medicine, vol. 135, p. 102450, 2023.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/36642485/>]

[22] M. Smith and L. Jones, "Deployment of machine learning web applications for clinical decision support," SoftwareX, vol. 20, p. 101220, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/36040850/>]

[23] C. H. Lee et al., "Clinical utility of explainable artificial intelligence in stroke risk stratification," Journal of Personalized Medicine, vol. 12, no. 3, p. 445, 2022.

[Có tại: <https://www.mdpi.com/2075-4426/12/3/445>]

[24] M. Ghassemi et al., "The false hope of current approaches to explainable artificial intelligence in health care," The Lancet Digital Health, vol. 3, no. 11, pp. e745-e750, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34711379/>]

[25] A. Nguyen et al., "Interdisciplinary education in digital health," International Journal of Medical Informatics, vol. 155, p. 104500, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34425370/>]

[26] M. Katan and A. Luft, "Global Burden of Stroke," *Seminars in Neurology*, vol. 38, no. 2, pp. 208-211, 2018.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/29791947/>]

[27] C. W. Tsao et al., "Heart Disease and Stroke Statistics—2022 Update," *Circulation*, vol. 145, no. 8, pp. e153-e639, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35078371/>]

[28] G. Thomalla et al., "Acute Ischemic Stroke Treatment: Time is Brain," *Cerebrovascular Diseases*, vol. 49, no. 4, pp. 385-393, 2020.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/32942284/>]

[29] L. Zhao et al., "Global burden of stroke and its risk factors," *The Lancet Neurology*, vol. 20, no. 10, pp. 795-820, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34487721/>]

[30] A. S. Akyea et al., "Performance of machine learning in stroke prediction," *European Journal of Preventive Cardiology*, vol. 29, no. 6, pp. 888-896, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34893820/>]

[31] X. Tang et al., "Explainable machine learning for stroke risk prediction: a study with SHAP interpretation," *Frontiers in Neurology*, vol. 13, p. 912042, 2022.

[Có tại: <https://www.frontiersin.org/articles/10.3389/fneur.2022.912042/full>]

[32] S. Asadi et al., "Machine learning algorithms in stroke prediction: A systematic review," *Health Science Reports*, vol. 5, no. 3, e642, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35509745/>]

[33] A. J. Sutton et al., "Evolution of clinical decision support systems," *Journal of Biomedical Informatics*, vol. 109, p. 103560, 2020.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/32827725/>]

[34] X. Liu et al., "Machine learning-based clinical decision support systems," *Artificial Intelligence in Medicine*, vol. 128, p. 102300, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35654520/>]

[35] Y. Zhang et al., "Uncovering non-linear clinical risk factors using ensemble learning," *IEEE Journal of Biomedical and Health Informatics*, vol. 26, no. 2, pp. 642-655, 2022.

[Có tại: <https://ieeexplore.ieee.org/document/9428520>]

[36] J. Amann et al., "The black-box challenge in medical AI," *npj Digital Medicine*, vol. 3, no. 1, p. 136, 2020.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/33140024/>]

[37] Q. Abbas et al., "Explainable AI in clinical decision support systems," *Healthcare*, vol. 10, no. 1, p. 112, 2022.

[Có tại: <https://www.mdpi.com/2227-9032/10/1/112>]

[38] M. R. Hossain et al., "Model for Early Detection of Brain Stroke Using Boosting Algorithms," *Diagnostics*, vol. 13, no. 11, p. 1894, 2023.

[Có tại: <https://www.mdpi.com/2075-4418/13/11/1894>]

[39] D. Mochura et al., "Improving stroke risk prediction by integrating XGBoost and explainable AI," *BMC Medical Informatics and Decision Making*, vol. 22, p. 163, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35729580/>]

[40] Z. Sheng et al., "Predictive models for acute ischemic stroke using LightGBM," BMC Public Health, vol. 22, p. 1025, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35596180/>]

[41] T. O. Omotehinwa et al., "Machine learning techniques for cardiovascular diseases prediction," Frontiers in Artificial Intelligence, vol. 5, p. 82005, 2022.

[Có tại: <https://www.frontiersin.org/articles/10.3389/frai.2022.82005/full>]

[42] N. Alam et al., "Machine Learning Approach to Enhance Stroke Prediction," Applied Sciences, vol. 12, no. 5, p. 2150, 2022.

[Có tại: <https://www.mdpi.com/2076-3417/12/5/2150>]

[43] S. A. Basharat et al., "Stroke prediction using machine learning from electronic health records," Informatics in Medicine Unlocked, vol. 25, p. 100652, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/34307845/>]

[44] N. F. A. Rahman et al., "Data preprocessing methodologies for stroke risk prediction," Journal of Healthcare Engineering, vol. 2021, Article ID 5619324, 2021.

[Có tại: <https://www.hindawi.com/journals/jhe/2021/5619324/>]

[45] Y. Khan et al., "Addressing class imbalance in cardiovascular prediction," IEEE Access, vol. 10, pp. 11200-11215, 2022.

[Có tại: <https://ieeexplore.ieee.org/document/9684520>]

[46] J. A. Olugbade et al., "Addressing class imbalance in healthcare data: A

review," IEEE Access, vol. 9, pp. 82345-82360, 2021.

[Có tại: <https://ieeexplore.ieee.org/document/9452040>]

[47] S. K. Sahu et al., "Optimized SMOTE technique for health monitoring systems," IEEE Transactions on Artificial Intelligence, vol. 3, no. 2, pp. 210-223, 2022.

[Có tại: <https://ieeexplore.ieee.org/document/9546850>]

[48] T. Le et al., "Evaluation of borderline-SMOTE in medical risk diagnosis," Computers in Biology and Medicine, vol. 132, p. 104350, 2021.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/33714080/>]

[49] A. Gicic et al., "Explainable artificial intelligence for stroke prediction," IEEE Access, vol. 9, pp. 12045-12060, 2021.

[Có tại: <https://ieeexplore.ieee.org/document/9328450>]

[50] J. Rodriguez et al., "Consistency of SHAP explanations in clinical prediction," Artificial Intelligence in Medicine, vol. 124, p. 102250, 2022.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/35183350/>]

[51] X. Tang et al., "Explainable machine learning for stroke prediction: SHAP interpretation," Frontiers in Neurology, vol. 13, p. 912042, 2022.

[Có tại: <https://www.frontiersin.org/articles/10.3389/fneur.2022.912042/full>]

[52] Q. Abbas, W. Jeong, and S. W. Lee, "Explainable AI in Clinical Decision Support," Healthcare, vol. 10, no. 1, p. 112, 2022.

[Có tại: <https://www.mdpi.com/2227-9032/10/1/112>]

[53] C. Lazar et al., "Evaluating machine learning models for stroke prediction," Medical Informatics, vol. 10, p. 10452, 2023.

[Có tại: <https://pubmed.ncbi.nlm.nih.gov/36854120/>]

[54] A. Sadeghi et al., "Machine learning for stroke prediction using imbalanced data," Scientific Reports, vol. 13, no. 1, p. 4512, 2023.

[Có tại: <https://www.nature.com/articles/s41598-023-31512-4>]

[55] T. O. Omotehinwa et al., "Machine learning techniques for cardiovascular diseases," Frontiers in Artificial Intelligence, vol. 5, p. 82005, 2022.

[Có tại: <https://www.frontiersin.org/articles/10.3389/frai.2022.82005/full>]